Projekt SAP

Patrik Modrić Josip Rončević Marko Vrkić Luka Zorić

2026-01-23

Raspodjela materije

0 Unos i pregled podataka

1 Testiranje i analiziranje raznih hipoteza

2 Jesu li među pobjednicima neki žanrovi češći

3 Jesu li neki žanrovi u prosjeku dulji od ostalih

4 Utjecaj starosti na ocjene

5 Možemo li naslutiti kako je film ocijenjen pomoću drugih značajki

6 Možemo li pomoću dostupnih značajki pouzdano razlikovati pobjednike od ostalih

0 Unos i pregled podataka

```
library(tidyverse)
```

```
## Warning: package 'tidyverse' was built under R version 4.4.3

## Warning: package 'ggplot2' was built under R version 4.4.3

## Warning: package 'tibble' was built under R version 4.4.3

## Warning: package 'tidyr' was built under R version 4.4.3

## Warning: package 'readr' was built under R version 4.4.3

## Warning: package 'purrr' was built under R version 4.4.3

## Warning: package 'dplyr' was built under R version 4.4.3

## Warning: package 'stringr' was built under R version 4.4.3

## Warning: package 'forcats' was built under R version 4.4.3

## Warning: package 'lubridate' was built under R version 4.4.3
```

```
## -- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
## v dplyr     1.1.4     v readr     2.1.6
## v forcats   1.0.1     v stringr   1.6.0
## v ggplot2   4.0.1     v tibble    3.3.0
## v lubridate 1.9.4     v tidyr     1.3.1
## v purrr     1.2.0
## -- Conflicts ------------------------------------------ tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

Unijeli smo ovaj library jer je potreban za izračune kasnije.

Mi imamo temu Oscari. Testirat ćemo razne hipoteze, prikazati neka naša očekivanja za neke situacije, donijeti zaključke na temelju rezultata.

Ukoliko nije eksplicitno drukčije napisano, uzimamo $\alpha = 0.05$.

0.1 Unos podataka

Unijet ćemo podatke u varijablu 'oscars' tako da imamo lako razumljivi kod.

```
oscars = read.csv("oscars_dataset.csv", sep=";")
```

0.2 Pregled podataka

Sad ćemo pregledati kategorije u datasetu i koje su vrste podaci. Ovo smo dodali zato da imamo jasan pregled s čim radimo, koje podatke kombinirati i uspoređivati.

```
data.frame(
  Column = names(oscars[-1]),
  Type = sapply(oscars[-1], class),
  row.names = NULL
)
```

```
##                    Column      Type
## 1                    Film character
## 2             Oscar.Year character
## 3  Film.Studio.Producer.s. character
## 4                   Award character
## 5         Year.of.Release   integer
## 6              Movie.Time   integer
## 7             Movie.Genre character
## 8              Main.Genre character
## 9                Subgenre character
## 10            IMDB.Rating   numeric
## 11            IMDB.Votes character
## 12         Content.Rating character
## 13             Directors character
## 14   Original.Release.Date character
## 15      Production.Company character
## 16      Tomatometer.Rating   numeric
```

```
## 17       Tomatometer.Count   numeric
## 18         Audience.Rating   numeric
## 19          Audience.Count   numeric
```

1 Testiranje i analiziranje raznih hipoteza

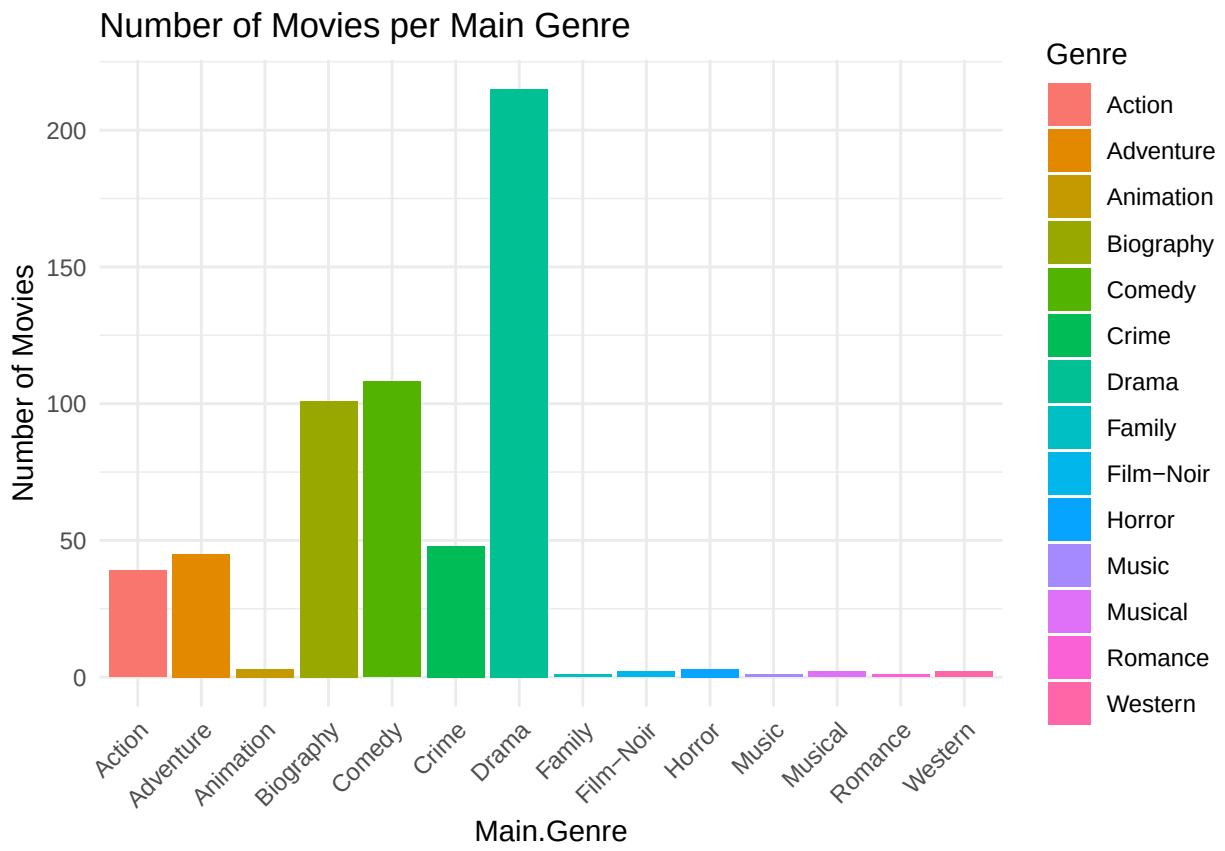
Mi smo smišljali razne hipoteze, testirali ih i gledali ima li nešto jači utjecaj, je li netko favoriziran, itd.

1.1 Opći pregled podataka

1.1.1 Broj filmova po glavnom žanru

Ovdje ćemo vidjeti dominaciju nekih žanrova, skroman prikaz drugih, te je li ujednačena podjela. Mi smatramo da, među glavnim žanrovima (Main.Genre), dominira drama. Tu smo hipotezu postavili na temelju našeg životnog iskustva i osobnog biasa.

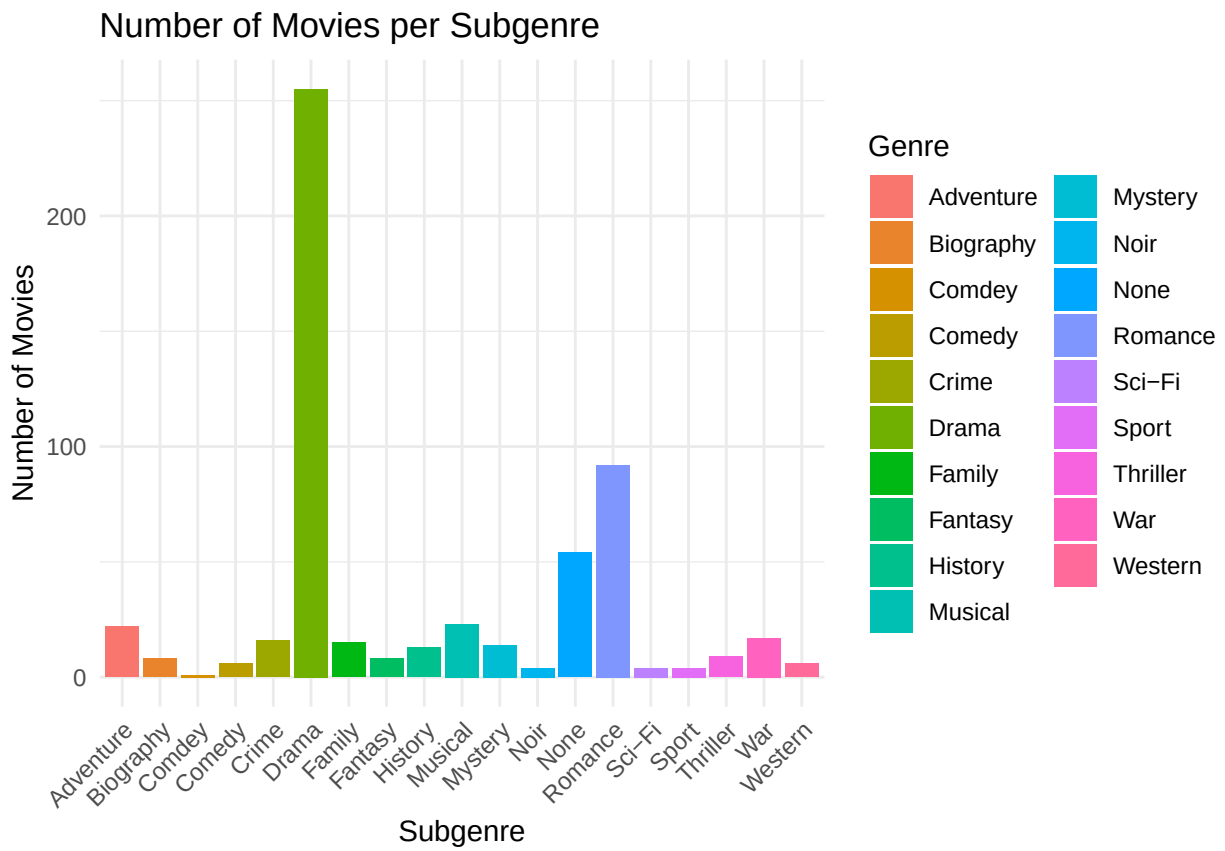
```
library(ggplot2)
genre_counts = table(oscars$Main.Genre)
genre_oscars = as.data.frame(genre_counts)
colnames(genre_oscars) = c("Genre", "Count")
ggplot(genre_oscars, aes(x = Genre, y = Count, fill = Genre)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  labs(title = "Number of Movies per Main Genre",
       x = "Main.Genre",
       y = "Number of Movies") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



1.1.2 Broj filmova po sporednom žanru

Ostavili smo legendu s desne strane grafa tako da bude lakše za čitati i brzi pregled žanrova.

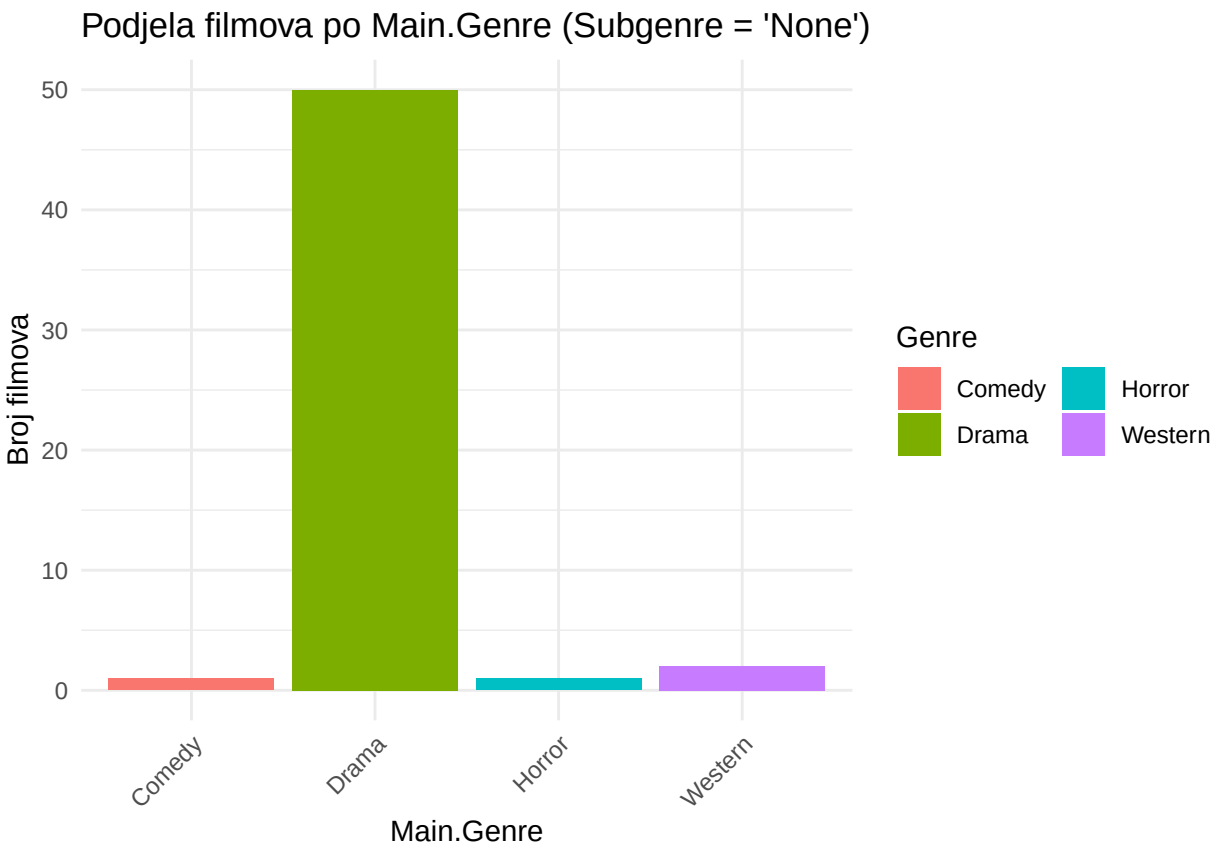
```
genre_counts = table(oscars$Subgenre)
genre_oscars = as.data.frame(genre_counts)
colnames(genre_oscars) = c("Genre", "Count")
ggplot(genre_oscars, aes(x = Genre, y = Count, fill = Genre)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  labs(title = "Number of Movies per Subgenre",
       x = "Subgenre",
       y = "Number of Movies") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  guides(fill = guide_legend(ncol = 2))
```



Rezultati nam govore da je dominacija drame još veća nego što smo mislili. Samo dva stupca su još ekstremnijeg izgleda, None i romantika. None nije rezultat starijih filmova već jednostavno činjenice da neki filmovi imaju samo jedan žanr, što je začuđujuće. Moglo bi se testirati koliko je podjela među žanrovima među filmovima koji nemaju žanr. Romantika je iznenađujuće velika. To nam govori da mnogo filmova ima kao sporedni razvoj događaja u samom filmu ljubavnu priču koja nije glavna tema priče. Možemo zaključiti da drame s romantičnim motivima imaju najviše šanse za dospijeti na nagrade Oscarsa.

1.1.3 Podjela filmova među glavnim žanrovima, a da nemaju sporedni žanr

```
oscars_none = subset(oscars, Subgenre == "None")
genre_counts = table(oscars_none$Main.Genre)
genre_oscars = as.data.frame(genre_counts)
colnames(genre_oscars) = c("Genre", "Count")
ggplot(genre_oscars, aes(x = Genre, y = Count, fill = Genre)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  labs(title = "Podjela filmova po Main.Genre (Subgenre = 'None')",
       x = "Main.Genre",
       y = "Broj filmova") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  guides(fill = guide_legend(ncol = 2))
```



Ovo je samo još jedan nepobitan dokaz da drama dominira, ili sama ili u kombinaciji s drugim žanrovima. Ovo je prikaz kad je drama jedini žanr.

1.2 Prosječno trajanje winners vs nominees

Mi tvrdimo da osvajanje nije povezano s duljinom filma.

H0: avg(osvojio) = avg(nije osvojio)

H1: avg(osvojio) != avg(nije osvojio)

Testiramo pomoću Z-testa jer je riječ o populaciji.

Riječ o kodu: uklanjamo filmove koji nemaju zabilježeno vrijeme trajanja jer mogu utjecati na broj filmova, a ne pridonose trajanju pa stvarno trajanje može biti manje nego što zapravo je. Mi ćemo to spriječiti uklanjanjem tih filmova.

```
winners = oscars$Movie.Time[oscars$Award == "Winner"]
nominees = oscars$Movie.Time[oscars$Award == "Nominee"]

winners = winners[!is.na(winners)]
nominees = nominees[!is.na(nominees)]

mean_w = mean(winners)
mean_n = mean(nominees)

sd_w = sd(winners)
```

```r
sd_n = sd(nominees)

n_w = length(winners)
n_n = length(nominees)

se = sqrt((sd_w^2 / n_w) + (sd_n^2 / n_n))

z_num = (mean_w - mean_n) / se
p_value = 2*(1-pnorm(abs(z_num)))
p_value
```

```
## [1] 2.846136e-06
```

```r
cat("Prosjek winners je: ", mean_w, "\n")
```

```
## Prosjek winners je:  138.266
```

```r
cat("Prosjek nominees je: ", mean_n, "\n")
```

```
## Prosjek nominees je:  122.26
```

```r
mean_all = (sum(winners) + sum(nominees)) / (length(winners) + length(nominees))
cat("Općenito prosječno trajanje je: ", mean_all, "\n")
```

```
## Općenito prosječno trajanje je:  124.8949
```

Definitivno možemo zaključiti da osvajači imaju duže prosječno trajanje, dok nominirani, tj. oni koji nisu osvojili, imaju kraće trajanje filma. S ovako niskom p-vrijednosti je odgovor poprilično točan.

Zanimljivo je opaziti da je prosječno trajanje puno bliže nominiranima nego osvajačima, zbog puno većeg udjela filmova koji su nominirani, jer ih je više nominirano, a samo jedan osvaja.

Ovo je jedna od mogućih značajki pomoću koje možemo 'predvidjeti' koji film će osvojiti Oscara.

2 Jesu li među pobjednicima neki žanrovi češći

Zanima nas postoji li veza između pobjednika i žanra dotičnog filma. Koristit ćemo χ^2 test nezavisnosti. Naša pretpostavka je da nema veze između pobjednika i njegovog žanra

H0: Raspodjela žanrova jednaka je za pobjednike i za nominirane

H1: Raspodjela žanrova razlikuje se između pobjednika i nominiranih

Prvo ćemo vidjeti raspodjelu žanrova među pobjednicima.

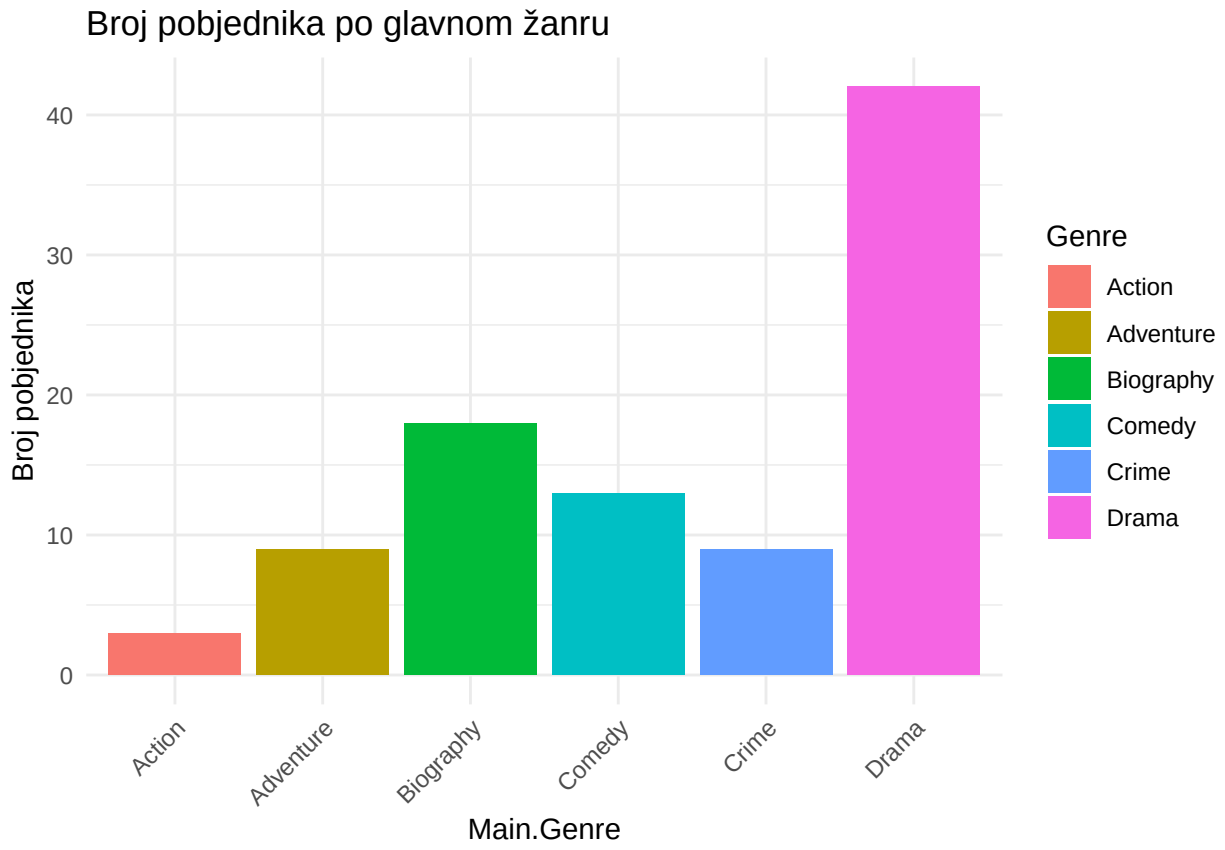
```r
library(ggplot2)

winners_only <- subset(oscars, Award == "Winner")

genre_counts_win <- table(winners_only$Main.Genre)
genre_win_df <- as.data.frame(genre_counts_win)
```

```r
colnames(genre_win_df) <- c("Genre", "Count")

ggplot(genre_win_df, aes(x = Genre, y = Count, fill = Genre)) +
  geom_bar(stat = "identity") +
  theme_minimal() +
  labs(title = "Broj pobjednika po glavnom žanru",
       x = "Main.Genre",
       y = "Broj pobjednika") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Među pobjednicima, drama dominira. Ovo nam govori da među nominiranima očekujemo dominaciju drame. Sad ćemo vidjeti brojčanu raspodjelu po žanru po dvije kategorije: pobjednik i nominirani.

```r
table(oscars$Main.Genre, oscars$Award)
```

```
##
##              Nominee Winner
##   Action          36      3
##   Adventure       36      9
##   Animation        3      0
##   Biography       83     18
##   Comedy          95     13
##   Crime           39      9
##   Drama          173     42
##   Family           1      0
```

```
##   Film-Noir       2      0
##   Horror          3      0
##   Music           1      0
##   Musical         2      0
##   Romance         1      0
##   Western         2      0
```

Ova raspodjela nije prikladna za χ^2 test jer postoji više kategorija koje imaju <5 elemenata. Grupirat ćemo te kategorije u druge kategorije s većim brojem filmova kako bismo mogli izvesti ovaj test. Grupirat ćemo ih prvo na osnovu žanra u Movie.Genre, onda u Subgenre. Ako ni tamo nema, stavit ćemo ih u dramu jer je drama daleko najpopularniji tip filma, kao što smo vidjeli ranije.

```
main_categories <- c("Action", "Adventure", "Biography", "Comedy", "Crime", "Drama")

# Funkcija koja određuje kojoj kategoriji pripada film
assign_genre <- function(main, movie, sub) {

  # Ako je već u glavnim kategorijama - ostavi
  if (main %in% main_categories) return(main)

  # Ako Movie.Genre sadrži neku od glavnih kategorija - koristi to
  for (cat in main_categories) {
    if (grepl(cat, movie, ignore.case = TRUE)) return(cat)
  }

  # Ako Subgenre sadrži neku od glavnih kategorija - koristi to
  for (cat in main_categories) {
    if (grepl(cat, sub, ignore.case = TRUE)) return(cat)
  }

  # Ako ništa nije pronađeno - stavi u Drama (najčešća kategorija među nominiranima)
  return("Drama")
}

oscars$Main.Genre.Collapsed <- mapply(
  assign_genre,
  oscars$Main.Genre,
  oscars$Movie.Genre,
  oscars$Subgenre
)

genre_award_table <- table(oscars$Main.Genre.Collapsed, oscars$Award)
genre_award_table
```

```
##
##             Nominee Winner
##   Action         36      3
##   Adventure      38      9
##   Biography      83     18
##   Comedy         95     13
##   Crime          39      9
##   Drama         186     42
```

```r
chi_test <- chisq.test(genre_award_table)
chi_test
```

```
##
##  Pearson's Chi-squared test
##
## data:  genre_award_table
## X-squared = 4.9202, df = 5, p-value = 0.4257
```

Zaključujemo da među pobjednicima, iako dominira žanr drama, nema povezanosti sa žanrom. Kod nominiranih je također više filmova žanra drama nego ostalih žanrova. p-vrijednost nam govori da nema povezanosti između pobjednika i njegovog žanra. Ne odbacujemo H0.

3 Jesu li neki žanrovi u prosjeku dulji od ostalih

Gledamo jesu li prosječno trajanje filma po žanru isto po svakom žanru. Ovo je uspoređivanje prosjeka grupa te gledanje jesu li barem neke dvije grupe različitih prosjeka. Koristit ćemo ANOVA test. Pretpostavljamo da su varijance svih grupa jednake.

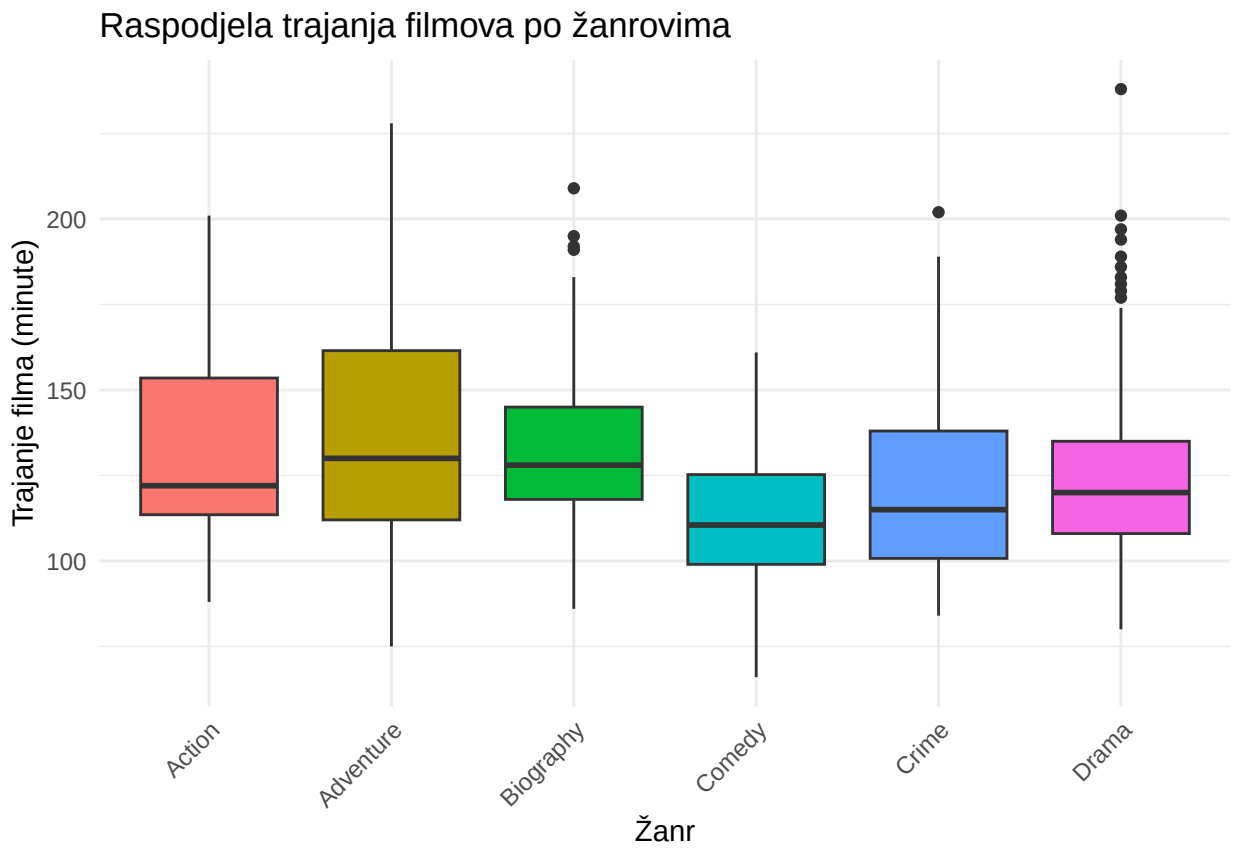
H0: $\mu_1 = \mu_2 = \cdots = \mu_n$

H1: barem dvije vrijednosti nisu jednake

Koristit ćemo skraćenu raspodjelu žanrova kako bi imali bolji prikaz prosjeka te da ne bi npr. prosjek film-noir žanra bio 98 minuta i kvario rezultate.

```r
library(ggplot2)

ggplot(oscars, aes(x = Main.Genre.Collapsed, y = Movie.Time, fill = Main.Genre.Collapsed)) +
  geom_boxplot() +
  theme_minimal() +
  labs(
    title = "Raspodjela trajanja filmova po žanrovima",
    x = "Žanr",
    y = "Trajanje filma (minute)"
  ) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1), legend.position = "none")
```



Medijani nam govore da je sredina vjerojatno jednaka za sve, ali interkvartilni rasponi filmova za action i adventure nam napućuje da treba odraditi dodatna testiranja. Njihovi su prosjeci vjerojatno veći od medijana i samim time je moguća razlika od žanra komedije.

Varijanca za žanrove adventure i drama izgleda drukčije nego varijanca za komediju. Treba testirati jesu li njihove varijance jednake kako bismo mogli koristiti točan test za gledanje jednakosti prosjeka trajanja

Koristit ćemo Bartlettov test za gledanje jednakosti varijanci.

H0: varijance su sve jednake

H1: barem dvije varijance nisu jednake

```
bartlett.test(Movie.Time ~ Main.Genre.Collapsed, data = oscars)
```

```
##
##  Bartlett test of homogeneity of variances
##
## data:  Movie.Time by Main.Genre.Collapsed
## Bartlett's K-squared = 36.658, df = 5, p-value = 7.014e-07
```

p-vrijednost je mnogo manja od 0.05. Odbacujemo H0. Nećemo koristiti ANOVA test jer varijance nisu jednake. Za testiranje jednakosti prosjeka ćemo koristiti Kruskal-Wallis test.

```
kruskal.test(Movie.Time ~ Main.Genre.Collapsed, data = oscars)
```

```
##
```

```
##  Kruskal-Wallis rank sum test
##
## data:  Movie.Time by Main.Genre.Collapsed
## Kruskal-Wallis chi-squared = 48.376, df = 5, p-value = 2.977e-09
```

Odbacujemo H0, prosjeci žanrova definitivno nisu jednaki.

Graf na početku odjeljka nas navodi da je stvar u žanru komedije, da nas on sputava u ostvarivanju jednakosti prosjeka trajanja filmova. Sad ćemo probati Kruskal-Wallis test bez žanra komedije.

```
# Izbacivanje komedije
oscars_no_comedy <- subset(oscars, Main.Genre.Collapsed != "Comedy")

# Kruskal-Wallis test
kruskal.test(Movie.Time ~ Main.Genre.Collapsed, data = oscars_no_comedy)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  Movie.Time by Main.Genre.Collapsed
## Kruskal-Wallis chi-squared = 15.288, df = 4, p-value = 0.00414
```

Nije bila stvar u žanru komedije, opet nisu jednaki prosjeci trajanja filmova.

4 Utjecaj starosti na ocjene

Kako bismo mogli postaviti hipoteze vezane uz utjecaj starosti na ocjene, prvo bi bilo dobro napraviti deskriptivnu analizu podataka. Sljedeći grafovi prikazuju podatke na različite načine i prema različitim izvorima ocjena.

4.1 Deskriptivna analiza

Za računanje kombinirane ocjene ćemo normalizirati ocjene Rotten Tomatoes i publike na skalu 0-10 da se poklapaju s IMDb ocjenama.

```
oscars$age = 2026 - oscars$Year.of.Release

oscars$age_group <- cut(
  oscars$age,
  breaks = c(0, 10, 20, 30, 40, 50, 60, 70, Inf),
  right = TRUE,
  include.lowest = TRUE,
  labels = c(
    "0-10 godina",
    "11-20 godina",
    "21-30 godina",
    "31-40 godina",
    "41-50 godina",
    "51-60 godina",
    "61-70 godina",
    "70+ godina"
```

```
  )
)

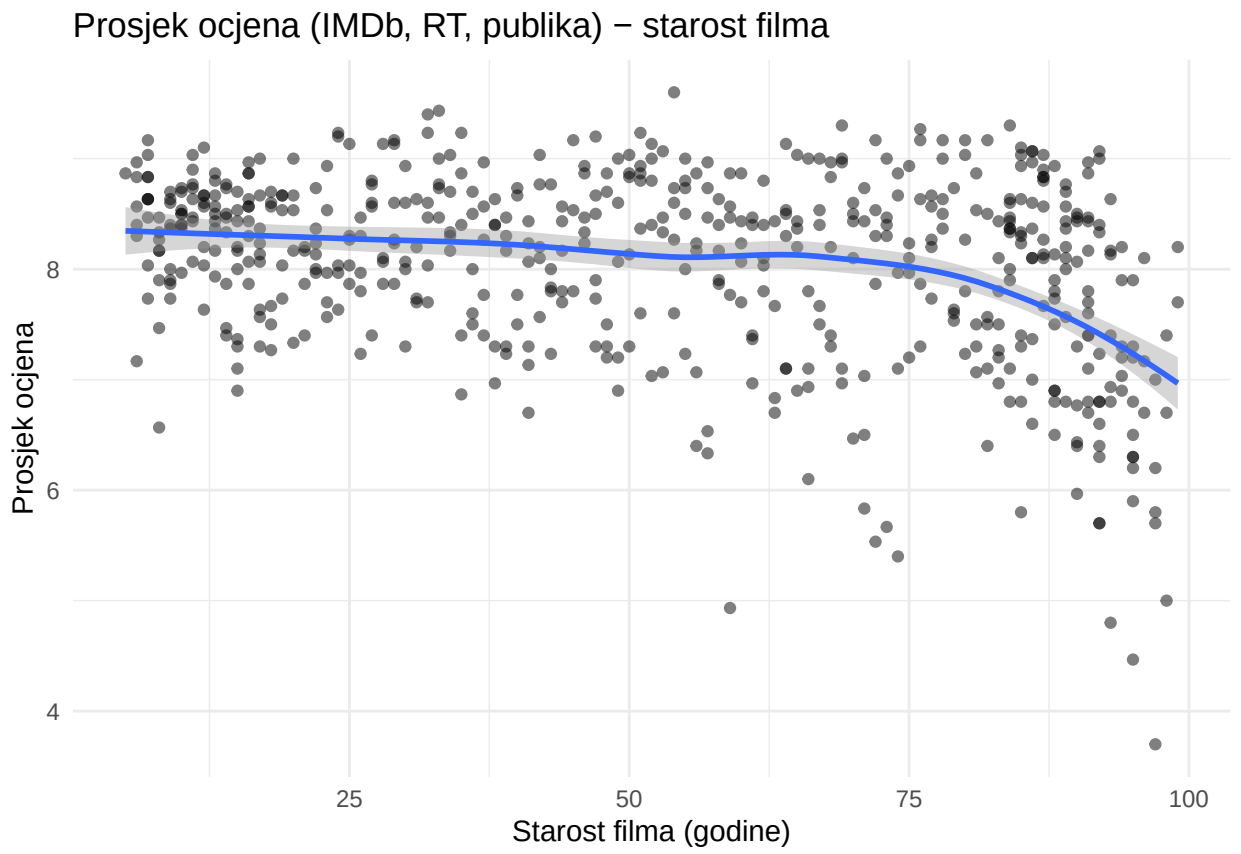
oscars$Tomatometer.Rating.normalised = oscars$Tomatometer.Rating / 10
oscars$Audience.Rating.normalised = oscars$Audience.Rating / 10
```

4.1.x Prosjek ocjena - točkasti graf

```
combined_rating <- rowMeans(
  oscars[, c("IMDB.Rating", "Tomatometer.Rating.normalised", "Audience.Rating.normalised")],
  na.rm = TRUE
)

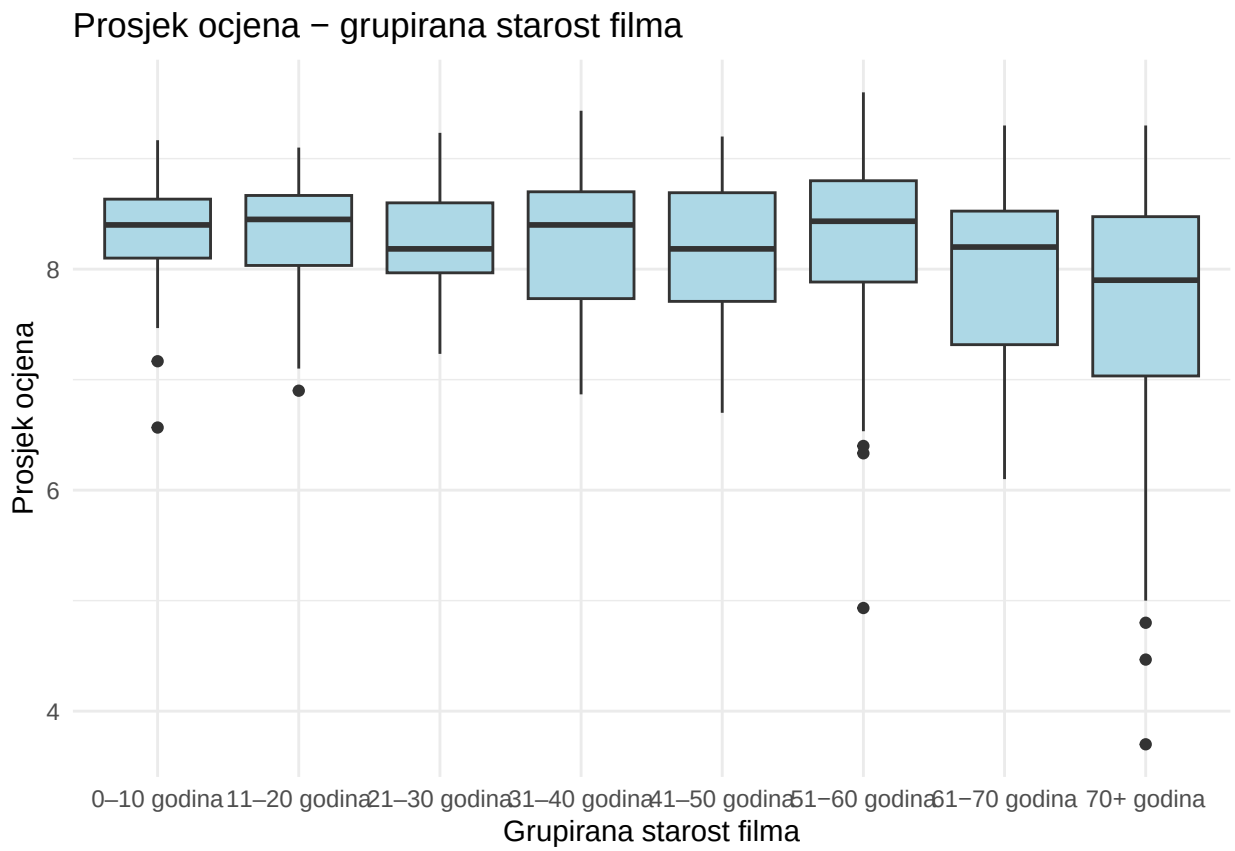
ggplot(oscars, aes(x = age, y = combined_rating)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "loess", se = TRUE) +
  labs(
    title = "Prosjek ocjena (IMDb, RT, publika) - starost filma",
    x = "Starost filma (godine)",
    y = "Prosjek ocjena"
  ) +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```



4.1.x Prosjek ocjena - boxplot

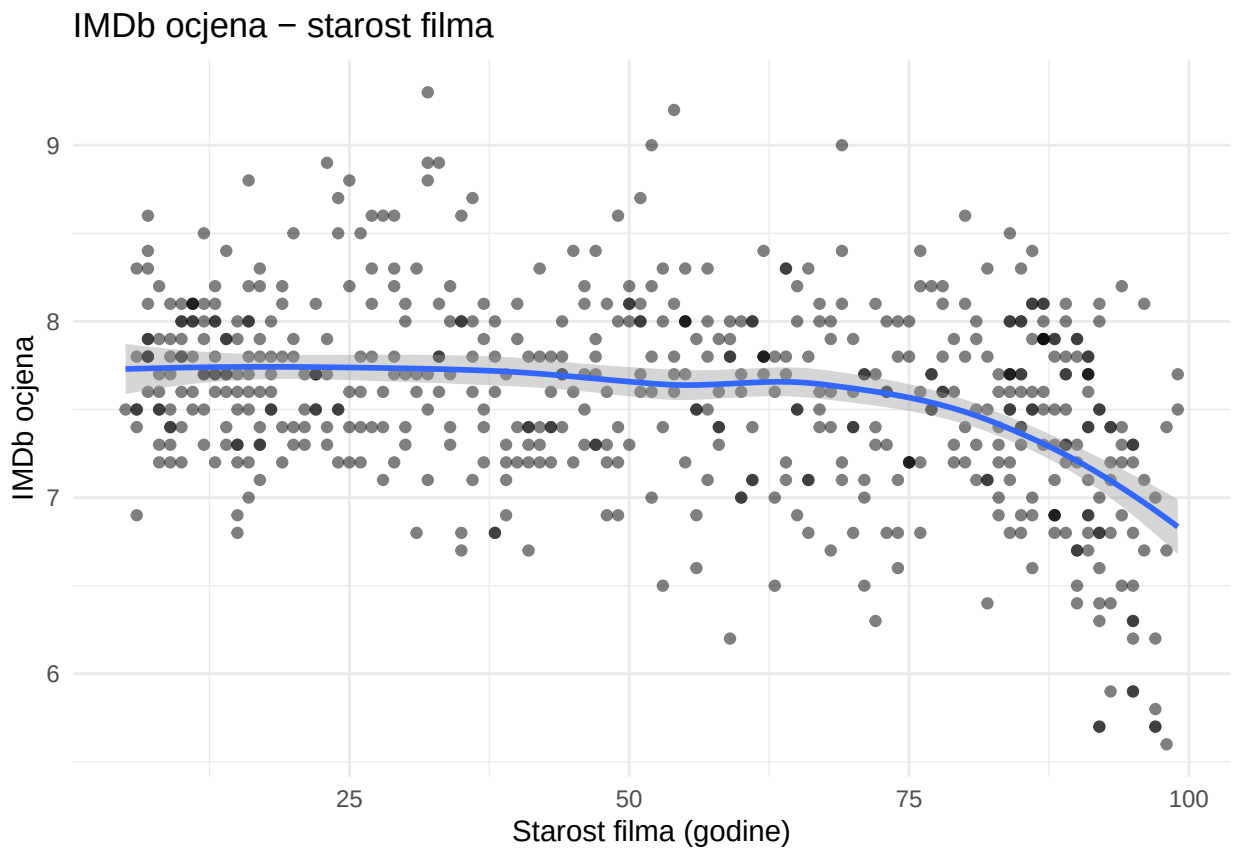
```
ggplot(oscars, aes(x = age_group, y = combined_rating)) +
  geom_boxplot(fill = "lightblue") +
  labs(
    title = "Prosjek ocjena - grupirana starost filma",
    x = "Grupirana starost filma",
    y = "Prosjek ocjena"
  ) +
  theme_minimal()
```



4.1.x IMDb - točkasti graf

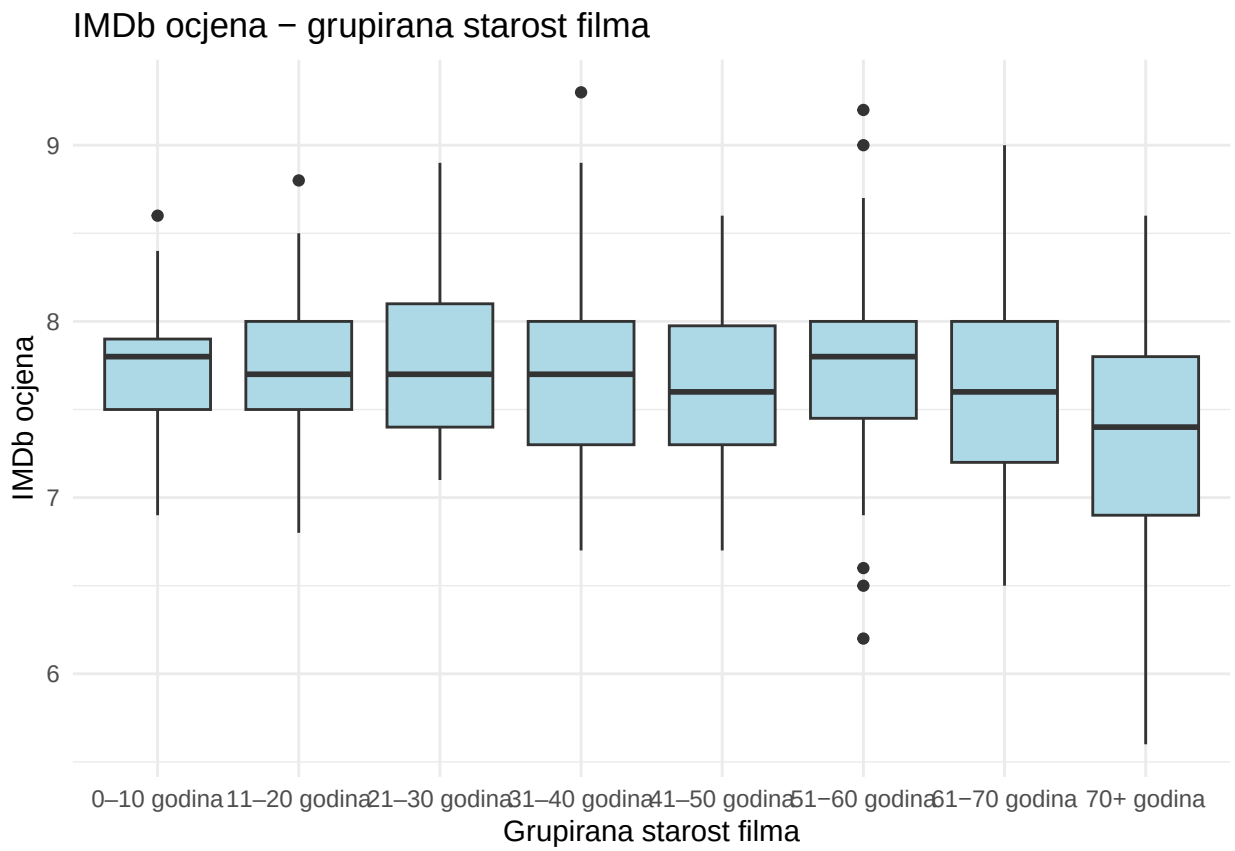
```
ggplot(oscars, aes(x = age, y = IMDB.Rating)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "loess", se = TRUE) +
  labs(
    title = "IMDb ocjena - starost filma",
    x = "Starost filma (godine)",
    y = "IMDb ocjena"
  ) +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```



4.1.x IMDb - boxplot

```
ggplot(oscars, aes(x = age_group, y = IMDB.Rating)) +
  geom_boxplot(fill = "lightblue") +
  labs(
    title = "IMDb ocjena - grupirana starost filma",
    x = "Grupirana starost filma",
    y = "IMDb ocjena"
  ) +
  theme_minimal()
```



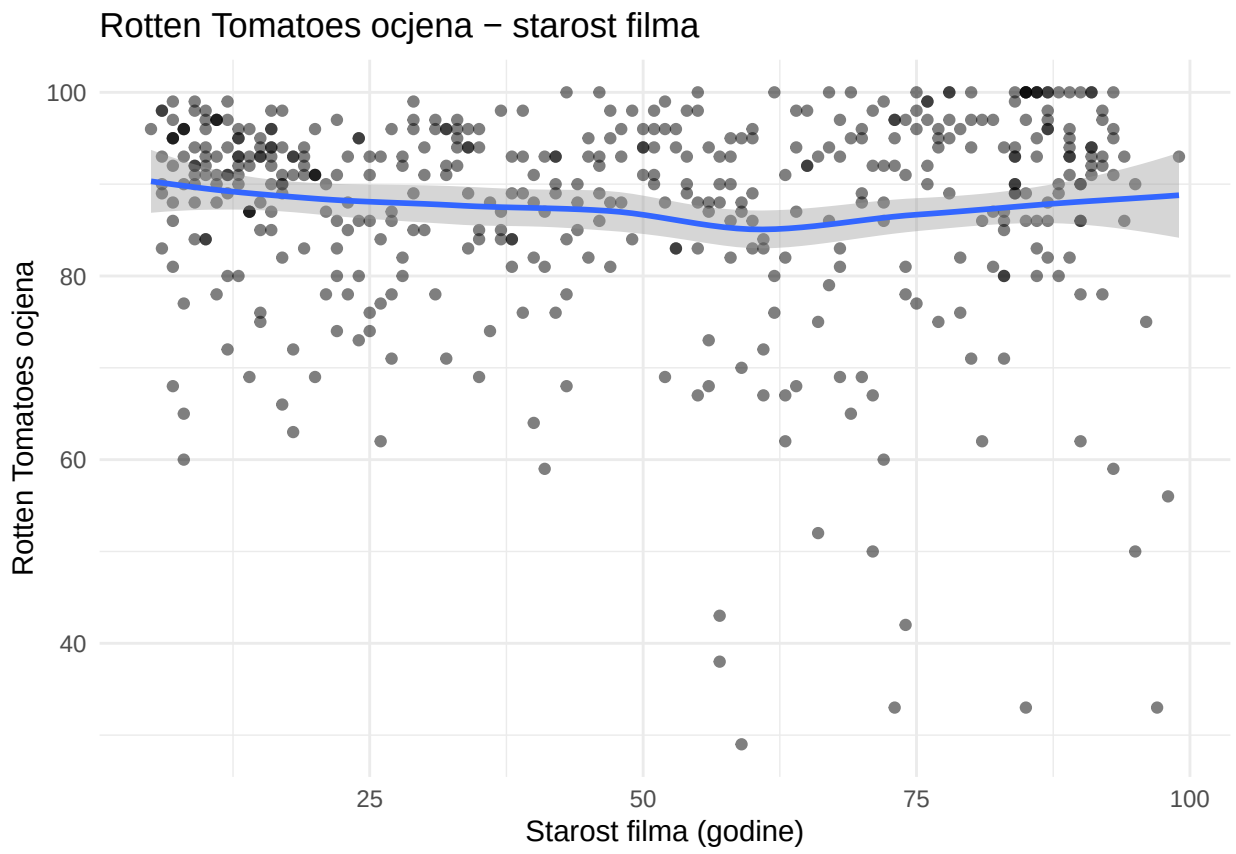
4.1.x Rotten Tomatoes - točkasti graf

```
ggplot(oscars, aes(x = age, y = Tomatometer.Rating)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "loess", se = TRUE) +
  labs(
    title = "Rotten Tomatoes ocjena - starost filma",
    x = "Starost filma (godine)",
    y = "Rotten Tomatoes ocjena"
  ) +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

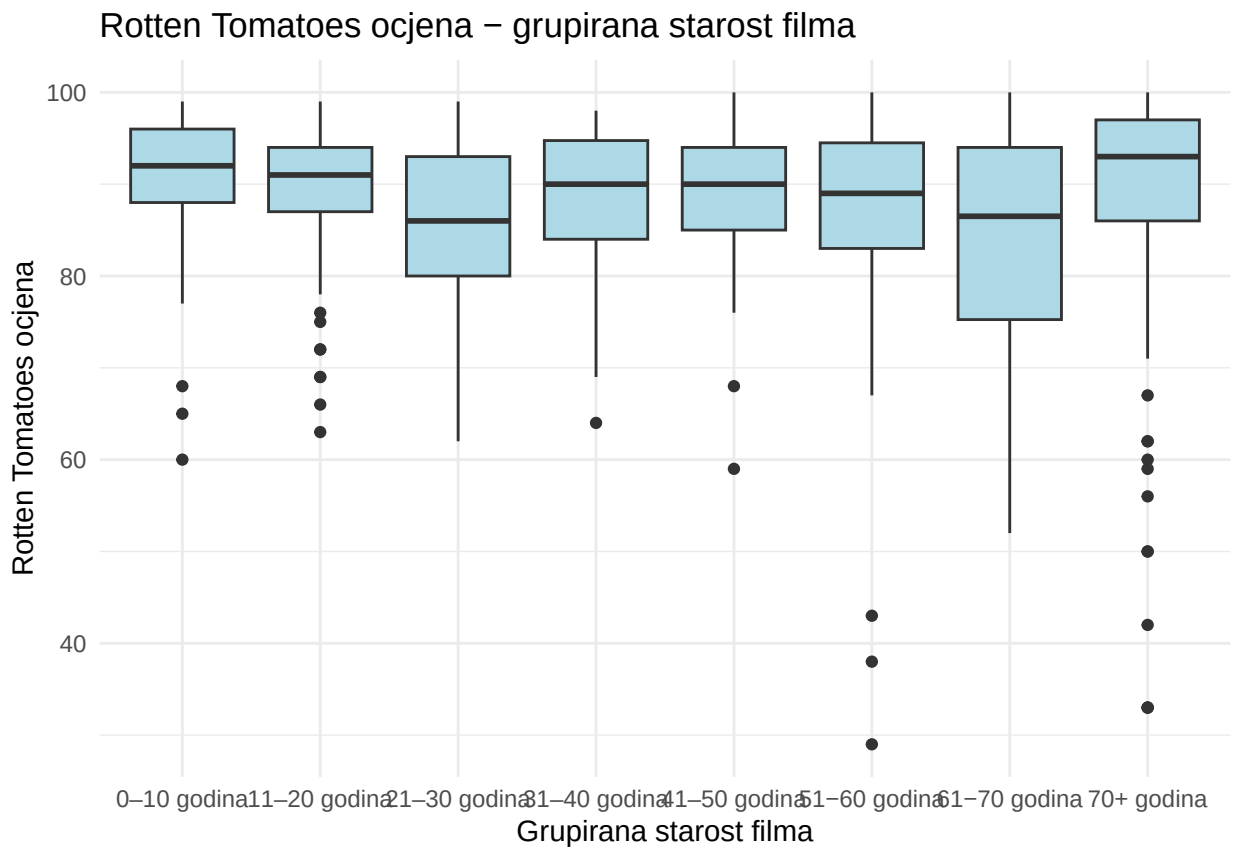
```
## Warning: Removed 112 rows containing missing values or values outside the scale range
## (`geom_point()`).
```



4.1.x Rotten Tomatoes - boxplot

```
ggplot(oscars, aes(x = age_group, y = Tomatometer.Rating)) +
  geom_boxplot(fill = "lightblue") +
  labs(
    title = "Rotten Tomatoes ocjena - grupirana starost filma",
    x = "Grupirana starost filma",
    y = "Rotten Tomatoes ocjena"
  ) +
  theme_minimal()
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (`stat_boxplot()`).
```



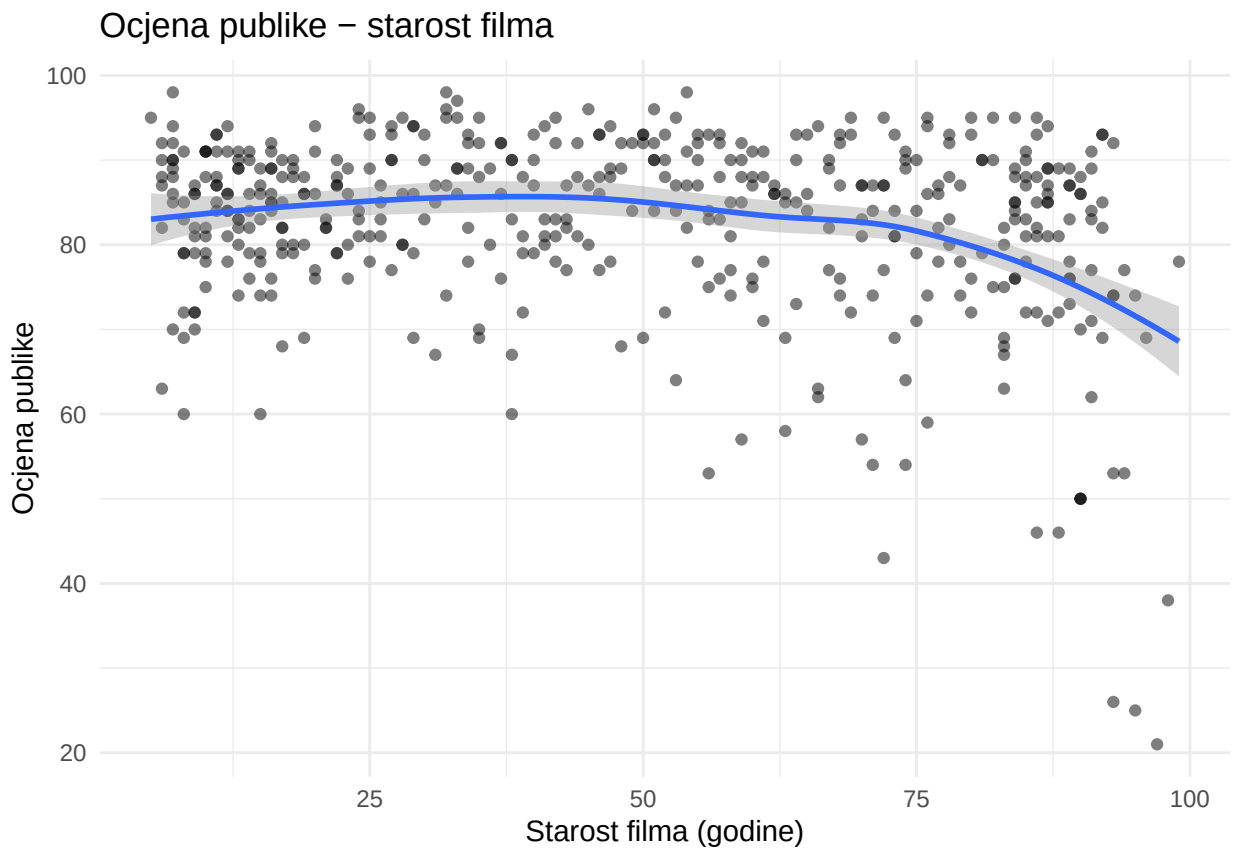
4.1.x Publika - točkasti graf

```
ggplot(oscars, aes(x = age, y = Audience.Rating)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "loess", se = TRUE) +
  labs(
    title = "Ocjena publike - starost filma",
    x = "Starost filma (godine)",
    y = "Ocjena publike"
  ) +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

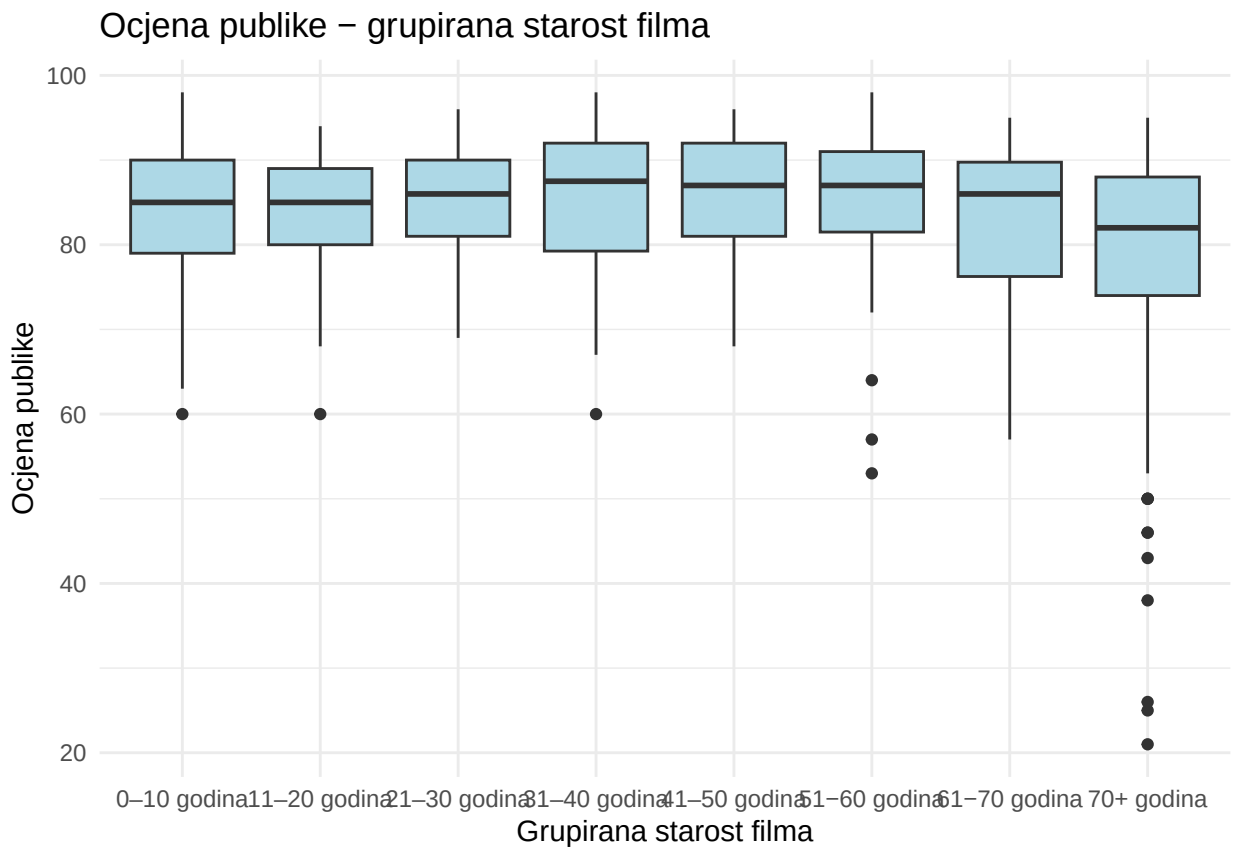
```
## Warning: Removed 112 rows containing missing values or values outside the scale range
## (`geom_point()`).
```



4.1.x Publika - boxplot

```
ggplot(oscars, aes(x = age_group, y = Audience.Rating)) +
  geom_boxplot(fill = "lightblue") +
  labs(
    title = "Ocjena publike - grupirana starost filma",
    x = "Grupirana starost filma",
    y = "Ocjena publike"
  ) +
  theme_minimal()
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (`stat_boxplot()`).
```



4.1.x Analiza

Iz prikazanih grafova vidimo kako IMDb i ocjene publike prate sličnu LOESS krivulju, dok su Rotten Tomatoes ocjene ujednačene tijekom godina. Pomoću LOESS krivulja i boxplot grafova uočavamo tendenciju da filmovi stariji od 70 godina prosječno imaju značajnije manje ocjene od ranijih filmova.

4.x Korelacija

Jedno od zanimljivijih pitanja je utječe li starost na ocjenu. To možemo provjeriti koeficijentom korelacije. Hipoteza je da je korelacija slaba zbog relativne ujednačenosti prosjeka ocjena tijekom godina i negativna zbog naglog pada ocjena u najstarijoj kategoriji.

```
cor(oscars$age, combined_rating, method = c("pearson"))
```

```
## [1] -0.3212074
```

```
cor(oscars$age, combined_rating, method = c("spearman"))
```

```
## [1] -0.2795706
```

Obje metode računanja korelacije daju negativne koeficijente blizu nule što potvrđuje našu hipotezu.

Još par metoda koje bi dale naslutiti takvu korelaciju su linearna i kvadratna regresija.

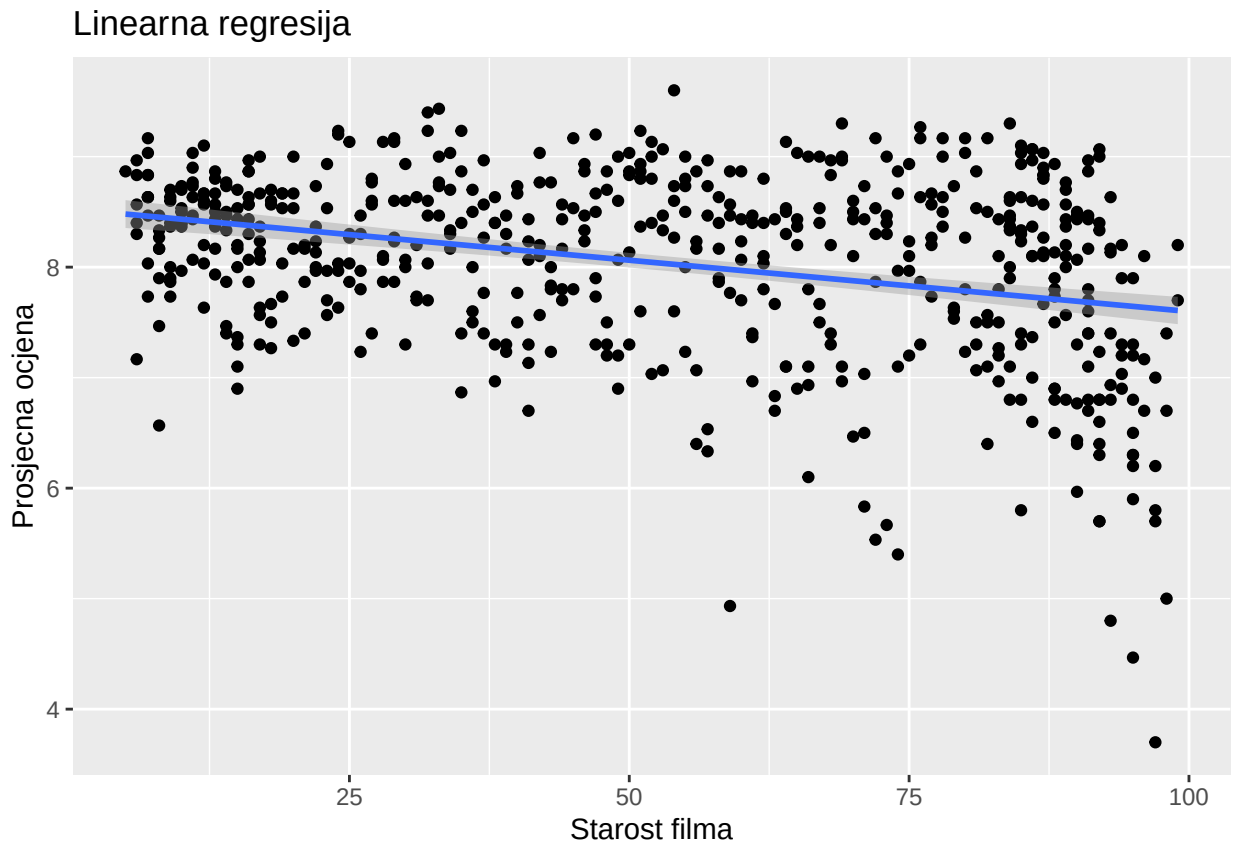
4.x Linearna regresija

```
lm_result <- lm(combined_rating ~ age, data = oscars)
summary(lm_result)
```

```
##
## Call:
## lm(formula = combined_rating ~ age, data = oscars)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -3.9263 -0.4800  0.0995  0.5649  1.5746
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  8.526621   0.069111 123.376  < 2e-16 ***
## age         -0.009282   0.001147  -8.091  3.6e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8029 on 569 degrees of freedom
## Multiple R-squared:  0.1032, Adjusted R-squared:  0.1016
## F-statistic: 65.46 on 1 and 569 DF,  p-value: 3.601e-15
```

```
ggplot(oscars, aes(x = age, y = combined_rating)) +
  geom_point() +
  geom_smooth(method = "lm", se = TRUE) +
  labs(
    title = "Linearna regresija",
    x = "Starost filma",
    y = "Prosječna ocjena"
  )
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

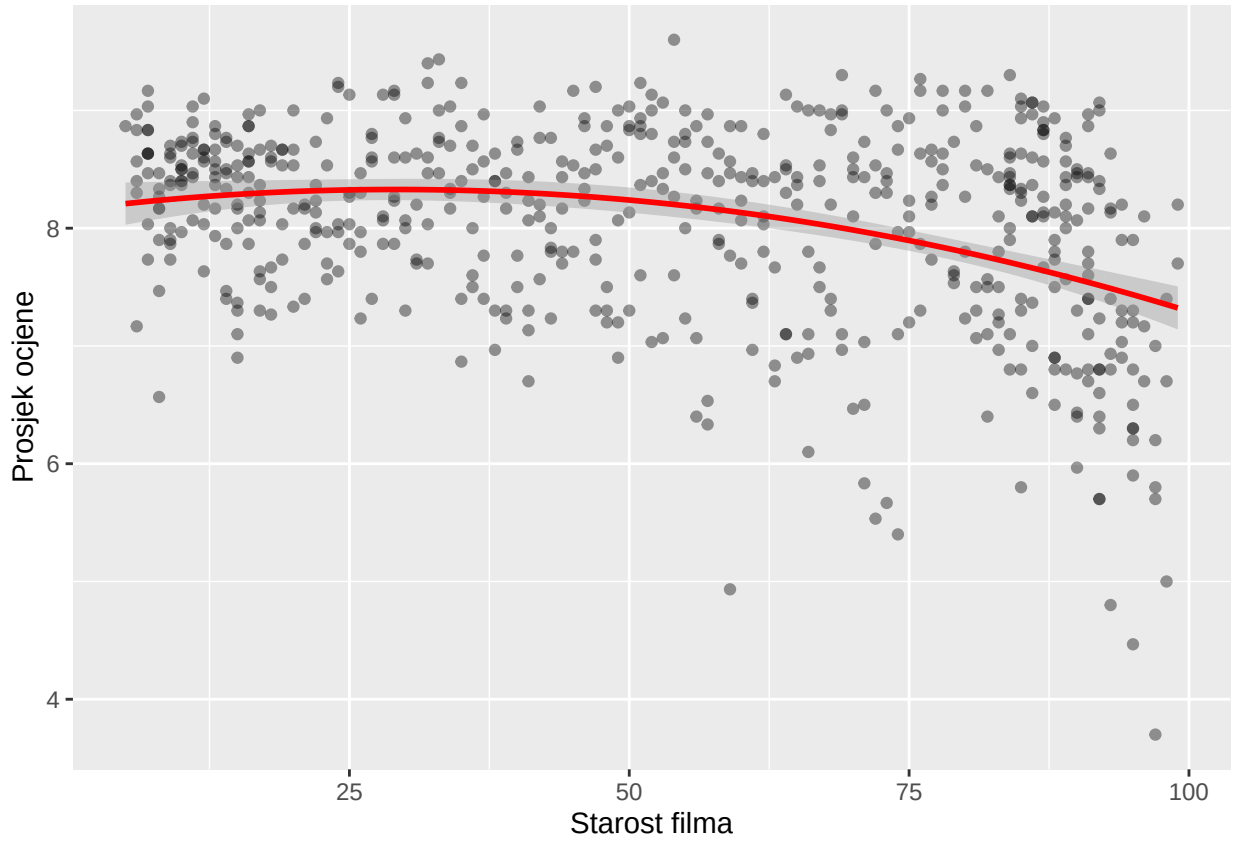


4.x Kvadratna regresija

```
poly_lm <- lm(combined_rating ~ poly(age, 2, raw = TRUE), data = oscars)
summary(poly_lm)
```

```
##
## Call:
## lm(formula = combined_rating ~ poly(age, 2, raw = TRUE), data = oscars)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -3.6798 -0.4799  0.1366  0.5562  1.5915
##
## Coefficients:
##                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  8.154e+00  1.134e-01  71.881  < 2e-16 ***
## poly(age, 2, raw = TRUE)1  1.201e-02  5.297e-03   2.267   0.0238 *
## poly(age, 2, raw = TRUE)2 -2.060e-04  5.008e-05  -4.114 4.47e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7919 on 568 degrees of freedom
## Multiple R-squared:  0.1291, Adjusted R-squared:  0.1261
## F-statistic: 42.11 on 2 and 568 DF,  p-value: < 2.2e-16
```

```
ggplot(oscars, aes(x = age, y = combined_rating)) +
  geom_point(alpha = 0.4) +
  stat_smooth(method = "lm", formula = y ~ poly(x, 2), se = TRUE, color = "red") +
  labs(x = "Starost filma", y = "Prosjek ocjene")
```



4.x ANOVA

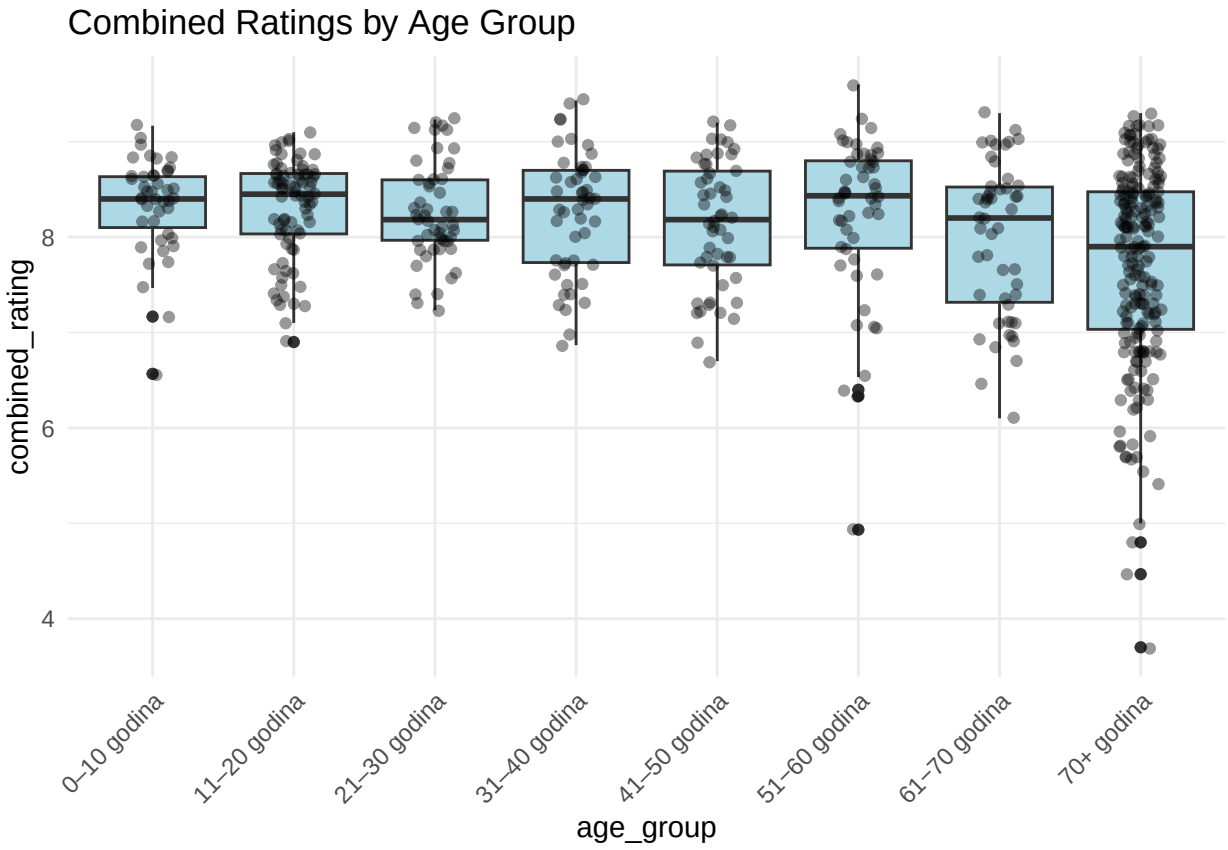
Grupa koja se najviše isticala prosječnom ocjenom bila je ona s filmovima starijim od 70 godina. Ono što bi bilo zanimljivo vidjeti je je li ta razlika statistički značajna. Početna hipoteza je da svaka grupa ima jednak prosjek ocjene. Alternativa je da nemaju sve grupe jednak prosjek. Nju možemo testirati ANOVA testom.

```
anova_result <- aov(combined_rating ~ age_group, data = oscars)
summary(anova_result)
```

```
##              Df Sum Sq Mean Sq F value   Pr(>F)
## age_group     7   37.3   5.326   8.066 2.31e-09 ***
## Residuals   563  371.8   0.660
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

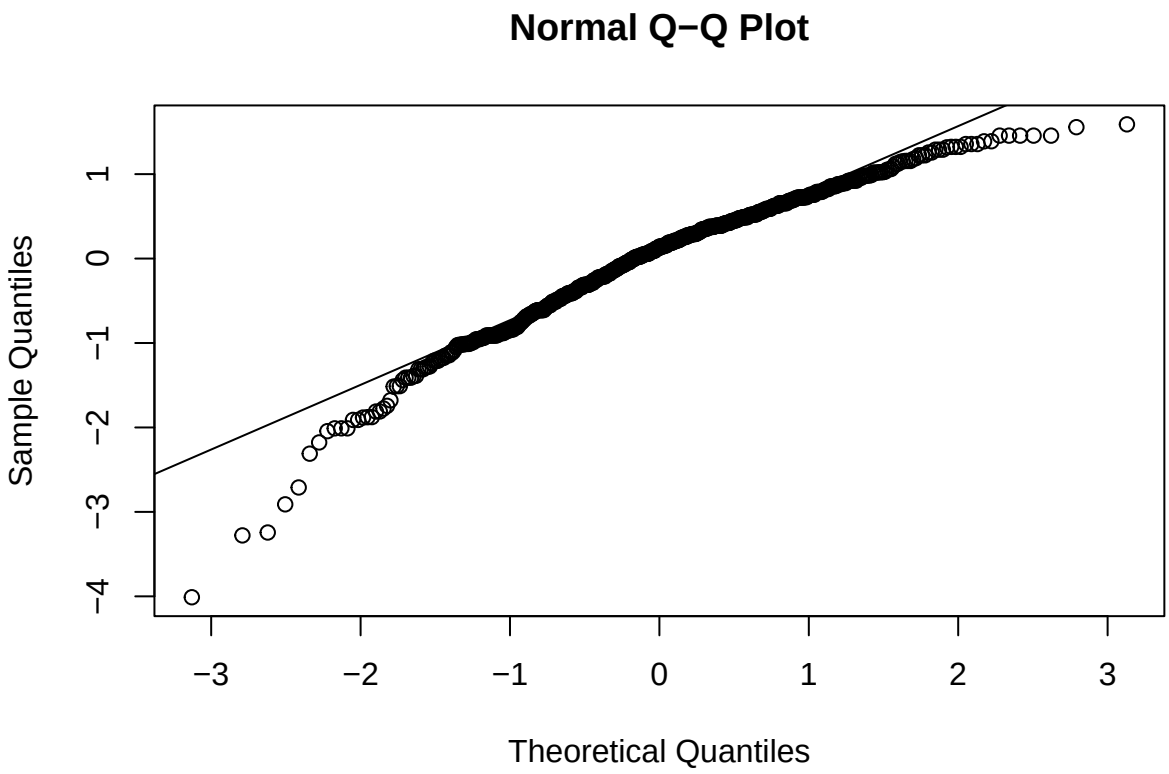
```
ggplot(oscars, aes(x = age_group, y = combined_rating)) +
  geom_boxplot(fill = "lightblue") +
  geom_jitter(width = 0.15, alpha = 0.4) +
```

```
  labs(title = "Combined Ratings by Age Group") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



ANOVA ima pretpostavku normalne distibucije reziduala pa je i to potrebno testirati da odlučimo je li to dobar test za ovaj set podataka.

```
qqnorm(residuals(anova_result))
qqline(residuals(anova_result))
```



Q-Q graf reziduala da naslutiti da njihova distribucija nije normalna što možemo testirati Shapiro-Wilk testom. Početna hipoteza je da je distribucija reziduala normalno distribuirana. Alternativna je da nije.

```
shapiro.test(residuals(anova_result))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(anova_result)
## W = 0.95915, p-value = 1.719e-11
```

p vrijednost testa je vrlo niska što ide u korist alternativnoj hipotezi. Budući da pretpostavka normalne distribucije nije vjerojatna, ANOVA test nije prikladan za ovaj set podataka. Stoga ćemo kao alternativu koristiti Kruskal-Wallis test.

4.x Kruskal-Wallis test

Početna hipoteza je da su medijani svih grupa jednaki. Alternativna je da nisu.

```
kruskal.test(combined_rating ~ age_group, data = oscars)
```

```
##
##  Kruskal-Wallis rank sum test
##
```

```
## data:  combined_rating by age_group
## Kruskal-Wallis chi-squared = 36.843, df = 7, p-value = 5.023e-06
```

p vrijednost testa je vrlo niska što ide u korist alternativne hipoteze. Time bi se dalo zaključiti da postoji statističi značajna razlika između medijana ocjene grupa.

4.x Tukey HSD

Da bolje ustanovimo koje su to grupe, koristit ćemo Tukey test.

```
TukeyHSD(anova_result)
```

```
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = combined_rating ~ age_group, data = oscars)
##
## $age_group
##                                     diff        lwr         upr     p adj
## 11-20 godina-0-10 godina  -0.050755317 -0.5203230  0.41881239 0.9999799
## 21-30 godina-0-10 godina  -0.089302326 -0.6034754  0.42487072 0.9995098
## 31-40 godina-0-10 godina  -0.087533618 -0.6041268  0.42905961 0.9995836
## 41-50 godina-0-10 godina  -0.203302326 -0.7174754  0.31087072 0.9309774
## 51-60 godina-0-10 godina  -0.130870953 -0.6427080  0.38096605 0.9941824
## 61-70 godina-0-10 godina  -0.359968992 -0.8741420  0.15420406 0.3968470
## 70+ godina-0-10 godina    -0.631968992 -1.0475359 -0.21640207 0.0001245
## 21-30 godina-11-20 godina -0.038547009 -0.4864250  0.40933101 0.9999958
## 31-40 godina-11-20 godina -0.036778301 -0.4874327  0.41387607 0.9999971
## 41-50 godina-11-20 godina -0.152547009 -0.6004250  0.29533101 0.9687485
## 51-60 godina-11-20 godina -0.080115636 -0.5253099  0.36507860 0.9993809
## 61-70 godina-11-20 godina -0.309213675 -0.7570917  0.13866434 0.4158441
## 70+ godina-11-20 godina   -0.581213675 -0.9112389 -0.25118843 0.0000034
## 31-40 godina-21-30 godina  0.001768707 -0.4951915  0.49872892 1.0000000
## 41-50 godina-21-30 godina -0.114000000 -0.6084439  0.38044394 0.9969439
## 51-60 godina-21-30 godina -0.041568627 -0.5335829  0.45044560 0.9999963
## 61-70 godina-21-30 godina -0.270666667 -0.7651106  0.22377728 0.7096504
## 70+ godina-21-30 godina   -0.542666667 -0.9335589 -0.15177441 0.0007333
## 41-50 godina-31-40 godina -0.115768707 -0.6127289  0.38119151 0.9967389
## 51-60 godina-31-40 godina -0.043337335 -0.5378802  0.45120553 0.9999953
## 61-70 godina-31-40 godina -0.272435374 -0.7693956  0.22452484 0.7081208
## 70+ godina-31-40 godina   -0.544435374 -0.9385057 -0.15036508 0.0007988
## 51-60 godina-41-50 godina  0.072431373 -0.4195829  0.56444560 0.9998369
## 61-70 godina-41-50 godina -0.156666667 -0.6511106  0.33777728 0.9791871
## 70+ godina-41-50 godina   -0.428666667 -0.8195589 -0.03777441 0.0202633
## 61-70 godina-51-60 godina -0.229098039 -0.7211123  0.26291619 0.8494910
## 70+ godina-51-60 godina   -0.501098039 -0.8889124 -0.11328372 0.0024032
## 70+ godina-61-70 godina   -0.272000000 -0.6628923  0.11889226 0.4051295
```

p vrijednosti ovog testa ukazuju na to da grupa najstarijih filmova najviše odskače medijanom ocjene od svih ostalih grupa. Iz toga možemo zaključiti da je razlika medijana ocjene između najstarije i ostalih grupa statistički značajna.

5 Možemo li naslutiti kako je film ocijenjen pomoću drugih značajki?

Nakon analize starosti filmova u odnosu na njihovu ocjenu, pogledat ćemo ostale značajke koji mogu eventualno utjecati na ocjenu filma. To mogu biti numeričke značajke poput trajanja filma ili količine glasova koji čine ocjenu, ali i kategorijske varijable kao što je podžanr ili Content.Rating. Prvo provjerimo u kakvom su odnosu tri sistema ocjena koje imamo u datasetu, provjeravajući njihovu korelaciju.

```
cor(oscars$IMDB.Rating, oscars$Audience.Rating, use = "complete.obs")
```

```
## [1] 0.8485251
```

Vidimo da su ocjene publike i IMDB ocjene poprilično slične.

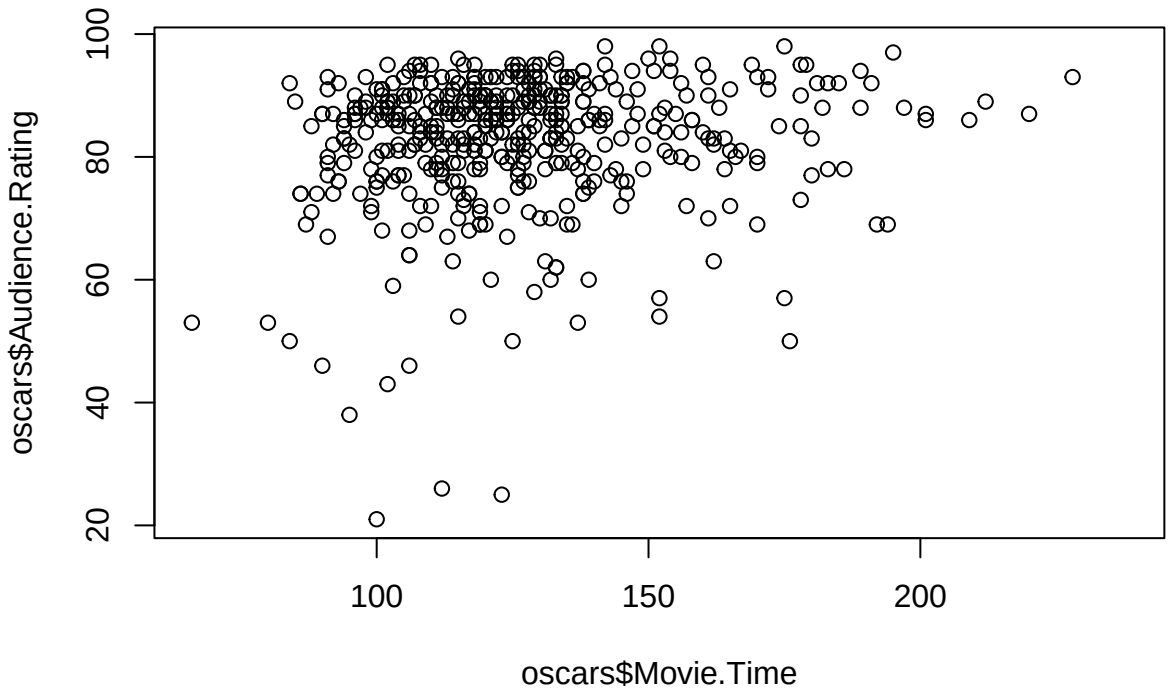
```
cor(oscars$Audience.Rating, oscars$Tomatometer.Rating, use = "complete.obs")
```

```
## [1] 0.5046268
```

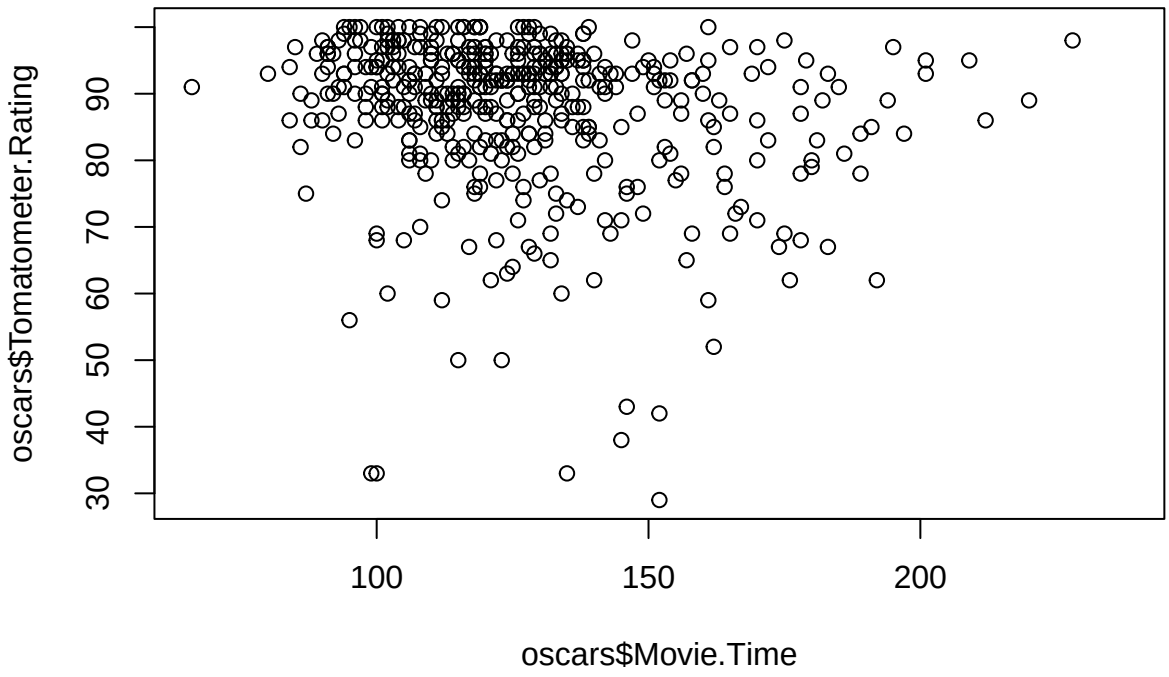
S druge strane, Tomatometer ocjene odstupaju od onih kod druga dva sistema. U sklopu ovog promatrat ćemo stoga ocjene gledatelja i ocjene na Tomatometeru.

Odnos ocjena i duljine trajanja filma:

```
plot(oscars$Movie.Time, oscars$Audience.Rating)
```



```r
plot(oscars$Movie.Time, oscars$Tomatometer.Rating)
```



Ne da se primijetiti neki očiti trend, osim možda činjenice da vrlo dugi filmovi (200+ minuta) ne dobivaju niske ocjene. Ako izračunamo korelaciju među ocjenom i trajanjem, uvjerit ćemo se da ova značajka utječe vrlo slabo na ocjenu filma:

```r
cor_audience <- cor(oscars$Movie.Time, oscars$Audience.Rating,
                    use = "complete.obs")
cor_tomatometer <- cor(oscars$Movie.Time, oscars$Tomatometer.Rating,
                       use = "complete.obs")

cat("Korelacija Movie.Time vs Audience.Rating:", cor_audience, "\n")
```

```
## Korelacija Movie.Time vs Audience.Rating: 0.1364725
```

```r
cat("Korelacija Movie.Time vs Tomatometer.Rating:", cor_tomatometer, "\n")
```

```
## Korelacija Movie.Time vs Tomatometer.Rating: -0.1896851
```

Broj ljudi koji su gledali film

Još jedna numerička značajka je i broj ljudi koji su ocijenili film.

```r
cor_aud_count <- cor(oscars$Audience.Count, oscars$Audience.Rating,
                     use = "complete.obs")
cor_tomato_count <- cor(oscars$Tomatometer.Count, oscars$Tomatometer.Rating,
                        use = "complete.obs")

cat("Korelacija Audience.Count <-> Audience.Rating:", cor_aud_count, "\n")
```

```
## Korelacija Audience.Count <-> Audience.Rating: -0.01560293
```

```r
cat("Korelacija Tomatometer.Count <-> Tomatometer.Rating:", cor_tomato_count, "\n\n")
```

```
## Korelacija Tomatometer.Count <-> Tomatometer.Rating: 0.1264453
```

Opet zaključujemo analizom korelacije da ne postoji značajna povezanost broja gledatelja i ocjene filma.

Content.Rating

Pogledajmo sada kategorijsku značajku dobnog ograničenja (Content.Rating).

```r
rating_summary <- oscars %>%
  group_by(oscars$Content.Rating) %>%
  summarise(
    n = n(),
    Avg_Audience = mean(Audience.Rating, na.rm = TRUE),
    Med_Audience = median(Audience.Rating, na.rm = TRUE),
    Avg_Tomatometer = mean(Tomatometer.Rating, na.rm = TRUE),
    Med_Tomatometer = median(Tomatometer.Rating, na.rm = TRUE),
    Avg_IMDB = mean(IMDB.Rating, na.rm = TRUE)
  ) %>%
  arrange(desc(Avg_Audience))

print(rating_summary)
```

```
## # A tibble: 6 x 7
##   `oscars$Content.Rating`     n Avg_Audience Med_Audience Avg_Tomatometer
##   <chr>                   <int>        <dbl>        <dbl>           <dbl>
## 1 "R"                       151         85.1           86            89.8
## 2 "PG-13"                    73         85.1           86            86.6
## 3 "PG"                       80         84.8           87            88.6
## 4 "G"                        48         80.0           83            85.2
## 5 "NR"                      107         76.9           82            85.7
## 6 ""                        112        NaN             NA           NaN
## # i 2 more variables: Med_Tomatometer <dbl>, Avg_IMDB <dbl>
```

Primjećujemo kako su na svim stranicama filmovi s rejtingom R oni s najvišom prosječnom ocjenom, dok se ocjene publike i Tomatometer razlikuju kod „drugoplasiranog'' (PG-13, odnosno PG).

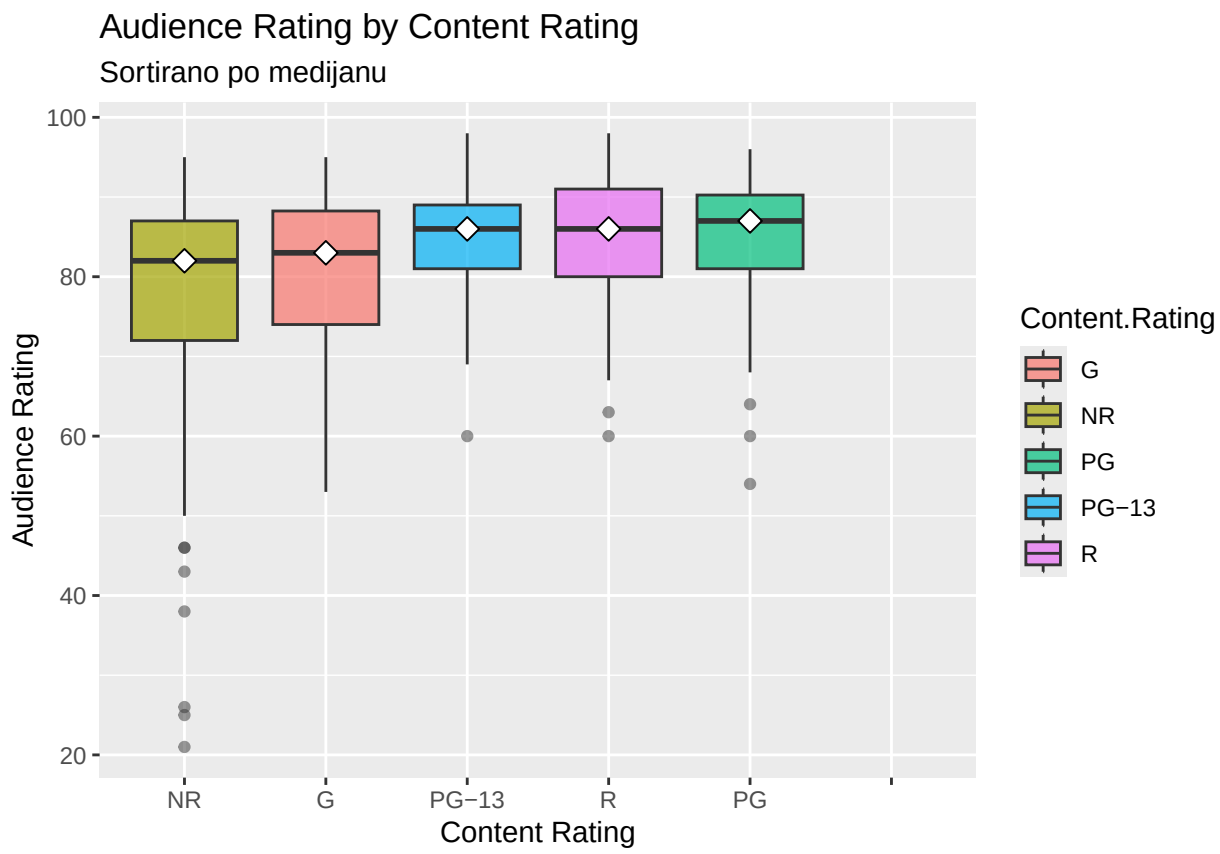
```r
p1 <- ggplot(oscars, aes(x = reorder(Content.Rating, Audience.Rating, median, na.rm = TRUE),
                         y = Audience.Rating,
                         fill = Content.Rating)) +
```

```
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.5) +
  stat_summary(fun = median, geom = "point", shape = 23, size = 3, fill = "white") +
  labs(title = "Audience Rating by Content Rating",
       subtitle = "Sortirano po medijanu",
       x = "Content Rating", y = "Audience Rating")

print(p1)
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (`stat_boxplot()`).
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (`stat_summary()`).
```

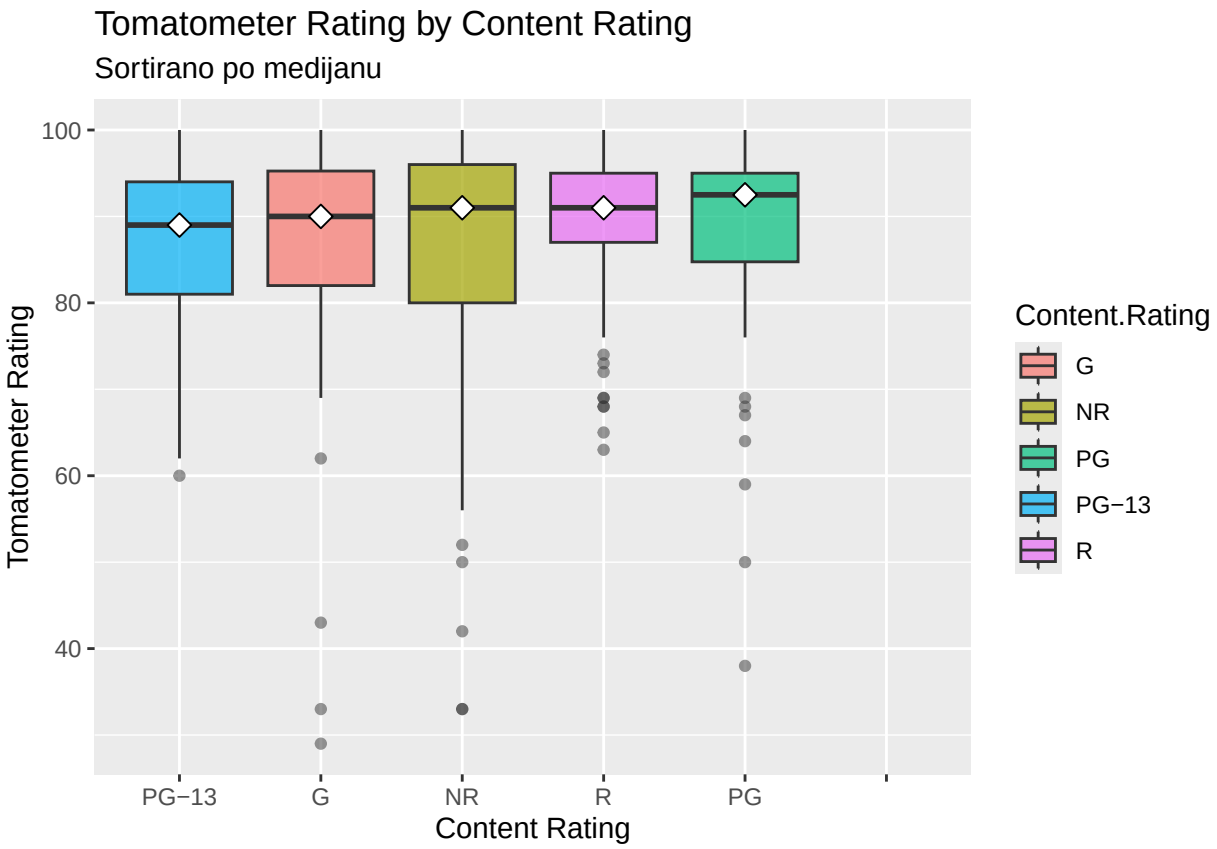



```
p2 <- ggplot(oscars, aes(x = reorder(Content.Rating, Tomatometer.Rating, median, na.rm = TRUE),
                         y = Tomatometer.Rating,
                         fill = Content.Rating)) +
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.5) +
  stat_summary(fun = median, geom = "point", shape = 23, size = 3, fill = "white") +
  labs(title = "Tomatometer Rating by Content Rating",
       subtitle = "Sortirano po medijanu",
       x = "Content Rating", y = "Tomatometer Rating")

print(p2)
```

```
## Warning: Removed 112 rows containing non-finite outside the scale range
## (‘stat_boxplot()‘).

## Warning: Removed 112 rows containing non-finite outside the scale range
## (‘stat_summary()‘).
```



Lako je uočiti kako filmovi zrelijeg sadržaja kod publike imaju više ocjene te uži IQR ocjena, dok filmovi s rejtingom G i oni bez rejtinga imaju niže prosječne ocjene i širi IQR. Filmovi bez rejtinga također imaju podosta stršećih vrijednosti, vrlo moguće zbog toga što ih je gledala generalna publika koja nije očekivala određenu prirodu filma bez njegova standardnog rejtinga. Kod Tomatometera da se vidjeti slični trend, no PG-13 je sada zadnji po prosječnoj ocjeni, a ima i širi IQR. Također, svi rejtinzi imaju puno više stršećih vrijednosti nego kod ocjena publike.

Utjecaj žanra i podžanra

```r
genre_analysis <- oscars %>%
  group_by(Main.Genre) %>%
  summarise(
    n = n(),
    Audience_Mean = mean(Audience.Rating, na.rm = TRUE),
    Tomatometer_Mean = mean(Tomatometer.Rating, na.rm = TRUE),
    IMDB_Mean = mean(IMDB.Rating, na.rm = TRUE)
  ) %>%
  filter(n >= 5) %>%  # samo zanrovi 5 ili vise filmova
```

```
  arrange(desc(Audience_Mean))

print(head(genre_analysis))
```

```
## # A tibble: 6 x 5
##   Main.Genre     n Audience_Mean Tomatometer_Mean IMDB_Mean
##   <chr>      <int>         <dbl>             <dbl>     <dbl>
## 1 Crime         48          86.6              90.6      7.88
## 2 Biography    101          84.8              85.9      7.58
## 3 Action        39          84.0              88        7.65
## 4 Comedy       108          81.7              90.2      7.47
## 5 Drama        215          81.1              87.2      7.56
## 6 Adventure     45          80.8              84.2      7.56
```

Kriminal je žanr koji na svim stranicama ima najveću prosječnu ocjenu. S druge strane, ocjene za komedije su jako varijabilne pa je tako taj žanr gotovo na dnu ocjena publike, ali je zato skoro na samom vrhu ocjena na Tomatometeru.

Podžanrova ima puno više:

```
oscars$Subgenre
```

```
##   [1] "Romance"   "Romance"   "Drama"     "Musical"   "Crime"     "Musical"
##   [7] "None"      "History"   "War"       "Drama"     "Drama"     "Drama"
##  [13] "Musical"   "Western"   "Romance"   "Drama"     "Drama"     "Adventure"
##  [19] "Romance"   "None"      "Romance"   "Sport"     "Drama"     "Musical"
##  [25] "Drama"     "Romance"   "Romance"   "Drama"     "Romance"   "Drama"
##  [31] "Drama"     "Family"    "Drama"     "Drama"     "Romance"   "Drama"
##  [37] "Romance"   "Drama"     "Drama"     "Romance"   "Musical"   "Drama"
##  [43] "Drama"     "Romance"   "Romance"   "Crime"     "Biography" "None"
##  [49] "Biography" "Drama"     "Romance"   "Adventure" "Drama"     "Drama"
##  [55] "Drama"     "Fantasy"   "History"   "Musical"   "Romance"   "Musical"
##  [61] "Drama"     "Drama"     "Romance"   "Romance"   "Drama"     "Romance"
##  [67] "Musical"   "Drama"     "History"   "Musical"   "Drama"     "Romance"
##  [73] "Drama"     "Drama"     "Romance"   "Drama"     "Drama"     "Drama"
##  [79] "Drama"     "Romance"   "Drama"     "Adventure" "Musical"   "Drama"
##  [85] "None"      "Musical"   "War"       "Romance"   "Drama"     "Romance"
##  [91] "History"   "Romance"   "Romance"   "Drama"     "Drama"     "Romance"
##  [97] "Drama"     "Drama"     "Family"    "Romance"   "Mystery"   "Romance"
## [103] "Romance"   "History"   "Drama"     "Romance"   "Drama"     "War"
## [109] "Romance"   "Romance"   "Family"    "Drama"     "Mystery"   "Fantasy"
## [115] "Romance"   "Romance"   "Noir"      "Drama"     "Drama"     "Mystery"
## [121] "Romance"   "Thriller"  "Mystery"   "Romance"   "War"       "Drama"
## [127] "Drama"     "Drama"     "Drama"     "Drama"     "Romance"   "Drama"
## [133] "Drama"     "Drama"     "War"       "Drama"     "Romance"   "Drama"
## [139] "Drama"     "Thriller"  "Drama"     "Drama"     "Drama"     "Romance"
## [145] "Drama"     "Noir"      "Fantasy"   "None"      "Drama"     "Mystery"
## [151] "Romance"   "Drama"     "Family"    "Romance"   "Family"    "Romance"
## [157] "Drama"     "Drama"     "Drama"     "Drama"     "None"      "None"
## [163] "Musical"   "Mystery"   "Drama"     "Noir"      "Drama"     "Romance"
## [169] "Romance"   "War"       "None"      "Drama"     "Romance"   "Adventure"
## [175] "Noir"      "Musical"   "War"       "Romance"   "Drama"     "None"
## [181] "Family"    "Thriller"  "Drama"     "Drama"     "Drama"     "Romance"
```

```
## [187] "Drama"     "History"   "Romance"   "Western"   "Drama"     "War"
## [193] "Musical"   "Drama"     "Romance"   "Romance"   "Drama"     "Drama"
## [199] "Romance"   "Drama"     "Comedy"    "Romance"   "Western"   "Drama"
## [205] "Drama"     "Drama"     "Drama"     "Romance"   "Romance"   "Drama"
## [211] "Musical"   "Drama"     "None"      "Drama"     "Romance"   "Drama"
## [217] "Drama"     "Drama"     "None"      "Romance"   "Drama"     "Drama"
## [223] "None"      "None"      "Drama"     "Drama"     "Romance"   "Adventure"
## [229] "Sport"     "War"       "Biography" "Drama"     "Family"    "Drama"
## [235] "Drama"     "Comedy"    "None"      "Drama"     "None"      "None"
## [241] "Family"    "Drama"     "None"      "Family"    "Drama"     "Drama"
## [247] "Romance"   "Romance"   "Romance"   "Drama"     "Drama"     "Drama"
## [253] "War"       "Drama"     "None"      "Drama"     "Biography" "Comedy"
## [259] "Drama"     "Drama"     "Family"    "Drama"     "Drama"     "Romance"
## [265] "Romance"   "None"      "Drama"     "Crime"     "Comedy"    "Drama"
## [271] "Drama"     "Drama"     "None"      "Romance"   "War"       "Crime"
## [277] "Drama"     "Family"    "Romance"   "Drama"     "Drama"     "Musical"
## [283] "Drama"     "History"   "Family"    "Drama"     "Drama"     "None"
## [289] "None"      "Romance"   "Drama"     "Mystery"   "Mystery"   "Drama"
## [295] "Drama"     "None"      "Drama"     "Crime"     "Thriller"  "Drama"
## [301] "Sport"     "Drama"     "Drama"     "None"      "Drama"     "Romance"
## [307] "Drama"     "None"      "Adventure" "Romance"   "War"       "Romance"
## [313] "Fantasy"   "Crime"     "Drama"     "None"      "Musical"   "Mystery"
## [319] "Drama"     "None"      "None"      "Drama"     "Drama"     "Drama"
## [325] "Romance"   "Drama"     "Drama"     "None"      "Adventure" "Mystery"
## [331] "Drama"     "Sci-Fi"    "Drama"     "Drama"     "None"      "Drama"
## [337] "Drama"     "None"      "Biography" "Musical"   "Drama"     "Drama"
## [343] "Drama"     "None"      "Drama"     "Drama"     "None"      "None"
## [349] "Drama"     "Drama"     "War"       "Romance"   "Drama"     "Drama"
## [355] "Romance"   "Drama"     "Drama"     "Thriller"  "Drama"     "Drama"
## [361] "None"      "Romance"   "Romance"   "Drama"     "Drama"     "None"
## [367] "War"       "Drama"     "Family"    "Drama"     "Drama"     "Drama"
## [373] "Fantasy"   "Drama"     "Crime"     "Drama"     "Family"    "Crime"
## [379] "History"   "Romance"   "Western"   "Drama"     "Thriller"  "Romance"
## [385] "None"      "Drama"     "Crime"     "Crime"     "Musical"   "Romance"
## [391] "Romance"   "Drama"     "Drama"     "Drama"     "None"      "Drama"
## [397] "Drama"     "Drama"     "Drama"     "Romance"   "Romance"   "Drama"
## [403] "Drama"     "Drama"     "Drama"     "Romance"   "Drama"     "Drama"
## [409] "Romance"   "Drama"     "Drama"     "Drama"     "Drama"     "War"
## [415] "War"       "None"      "Romance"   "Drama"     "Drama"     "Mystery"
## [421] "Adventure" "Romance"   "Adventure" "Drama"     "Drama"     "Drama"
## [427] "Drama"     "Drama"     "Adventure" "Musical"   "Crime"     "Drama"
## [433] "Romance"   "Adventure" "Drama"     "Adventure" "Drama"     "Adventure"
## [439] "Drama"     "History"   "Sport"     "Drama"     "Drama"     "Drama"
## [445] "Drama"     "Drama"     "Romance"   "Crime"     "Drama"     "Drama"
## [451] "Drama"     "None"      "Adventure" "Drama"     "Drama"     "Drama"
## [457] "Mystery"   "Drama"     "Drama"     "None"      "Romance"   "Fantasy"
## [463] "Drama"     "Drama"     "Romance"   "Thriller"  "Adventure" "Drama"
## [469] "Sci-Fi"    "None"      "Drama"     "None"      "Drama"     "Adventure"
## [475] "Drama"     "Drama"     "Drama"     "Thriller"  "Drama"     "Adventure"
## [481] "Drama"     "Drama"     "Adventure" "Western"   "Mystery"   "Drama"
## [487] "Drama"     "Drama"     "None"      "Family"    "Fantasy"   "Drama"
## [493] "Fantasy"   "Adventure" "Drama"     "None"      "Drama"     "Western"
## [499] "Drama"     "Drama"     "History"   "Drama"     "History"   "Drama"
## [505] "Drama"     "Biography" "Drama"     "Sci-Fi"    "Romance"   "Drama"
```

```
## [511] "Drama"     "Crime"     "Drama"     "Biography" "None"      "Comedy"
## [517] "Drama"     "Drama"     "Drama"     "Musical"   "Crime"     "Drama"
## [523] "History"   "Romance"   "Adventure" "Drama"     "Adventure" "Thriller"
## [529] "None"      "Sci-Fi"    "None"      "Drama"     "Crime"     "Drama"
## [535] "Drama"     "Drama"     "None"      "Drama"     "Romance"   "Drama"
## [541] "Drama"     "Mystery"   "Drama"     "Romance"   "None"      "Drama"
## [547] "Drama"     "Adventure" "Comedy"    "Drama"     "Drama"     "None"
## [553] "Musical"   "Comdey"    "Drama"     "War"       "Biography" "Crime"
## [559] "Drama"     "Drama"     "Romance"   "Drama"     "Drama"     "None"
## [565] "None"      "Drama"     "Drama"     "None"      "Drama"     "Musical"
## [571] "History"
```

```
subgenre_stats <- oscars %>%
  filter(!is.na(Subgenre) & Subgenre != "" & Subgenre != "N/A") %>%
  group_by(Subgenre) %>%
  summarise(
    n = n(),
    Audience_Mean = mean(Audience.Rating, na.rm = TRUE),
    Tomatometer_Mean = mean(Tomatometer.Rating, na.rm = TRUE),
    IMDB_Mean = mean(IMDB.Rating, na.rm = TRUE)
  ) %>%
  filter(n >= 5) %>%
  arrange(desc(Audience_Mean))

print(head(subgenre_stats, 15))
```

```
## # A tibble: 15 x 5
##    Subgenre      n Audience_Mean Tomatometer_Mean IMDB_Mean
##    <chr>     <int>         <dbl>             <dbl>     <dbl>
##  1 Biography     8          89.2              89.3      7.65
##  2 Crime        16          87.1              92.6      7.67
##  3 Adventure    22          85.4              90.6      7.95
##  4 Mystery      14          85.1              95.5      7.8
##  5 None         54          84.7              89.7      7.65
##  6 Drama       255          83.8              87.5      7.58
##  7 Family       15          83.6              88.5      7.64
##  8 War          17          83.6              89.8      7.69
##  9 Thriller      9          82.9              87.4      7.64
## 10 History      13          82.6              79.4      7.66
## 11 Romance      92          79.0              85.7      7.40
## 12 Western       6          77                86.8      7.55
## 13 Musical      23          75.8              86.9      7.25
## 14 Fantasy       8          74.4              83.1      7.24
## 15 Comedy        6          69.5              68.3      7.03
```

Još jednom vidimo kako žanrovi variraju ovisno o sustavu ocjena.

Nakon pregleda nekih značajki u odnosu na ocjene filmova, moglo bi se reći da možemo naslutiti nešto o ocjeni filma primarno iz njenog žanra i dobnog ograničenja (Content rating), dok se čini da se popularnost (broj ocjena) i trajanje filma ne odražaju u njegovoj ocjeni.

6 Možemo li pomoću dostupnih značajki pouzdano razlikovati pobjednike od ostalih

Gledat ćemo završene dodjele nagrade, nećemo predviđati.

Kad uspoređujemo pobjednika s nominiranim tim filmovima, ponekad gledamo značajke filma, gledamo ih i pitamo se zašto je baš taj film osvojio, a ne jedan od preostalih.

Nakon nekog vremena, ocjene filmova se stabiliziraju te možemo gledati razlike između ocjene pobjednika i nominiranih.

Bitno je vrijeme izlaska, u smislu datuma u godini dana koja je prethodila dodjeli nagrada. Ako je film izašao predavno, bude zaboravljen do dodjele nagrada, a ako bude prenov film onda se ne pročuje dovoljno o njemu pa su mu šanse manje za osvajanje.

U odjeljku 1.3 smo uspoređivali prosječno trajanje nominiranih i pobjendika. Razlika postoji. Vrijeme trajanja je jedna od značajki.

U odjeljku 2 smo vidjeli da raspodjela žanrova među pobjednicima je jednaka raspodjeli žanrova nominiranih filmova. Žanr nam ne naslućuje je li film mogući pobjednik.

Redatelj, kao i producent, nam ne govori tko je pobjednik, jer je puno puta film osvojio, a da je tom redatelju, ili producentu, bio prvi put da je njegov film osvojio.

Production company je zanimljiva značajka. Treba ju testirati.

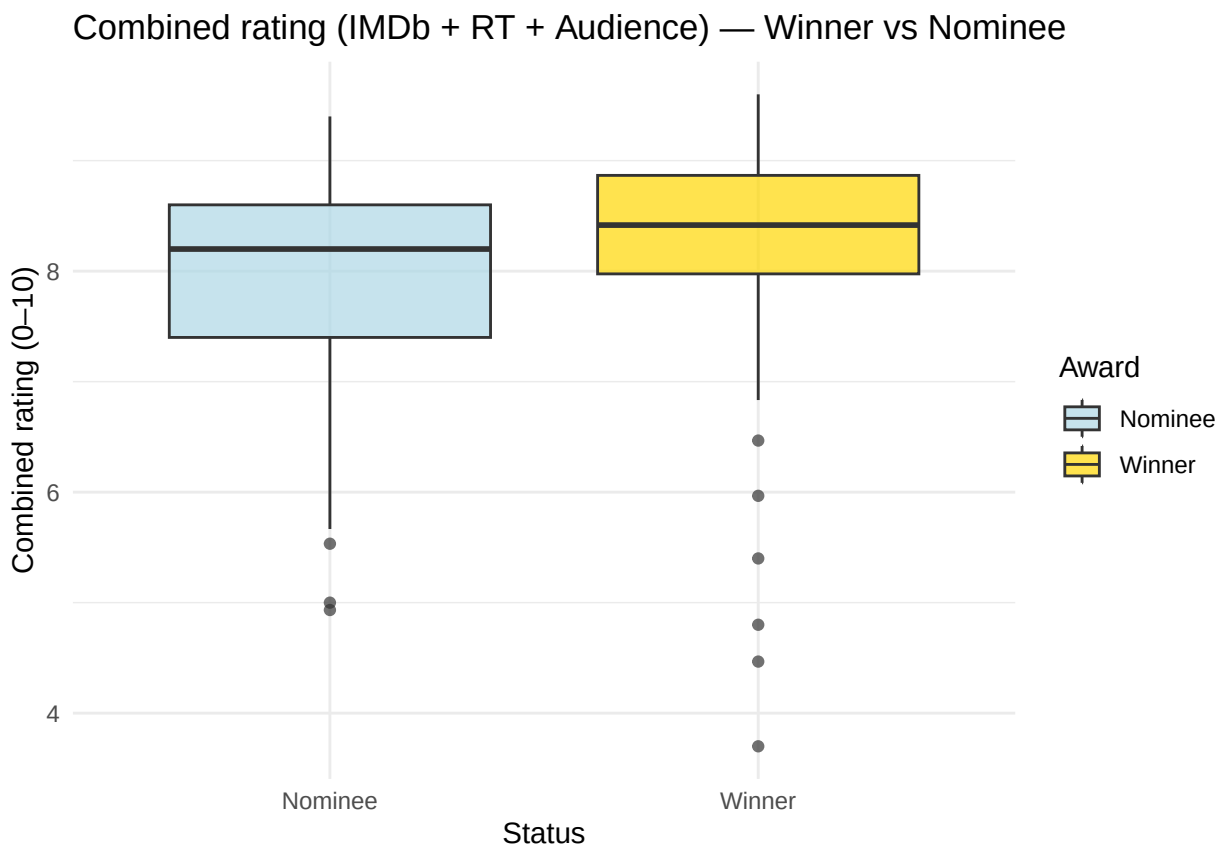
Dakle, moguće značajke su ocjene filmova, vrijeme izlaska, production company. Definitivne značajke su vrijeme trajanja. Značajke koje sigurno ne naslućuju su žanr, redatelj, producent.

6.1 Testiranje mogućih značajki

6.1.1 Ocjene filma

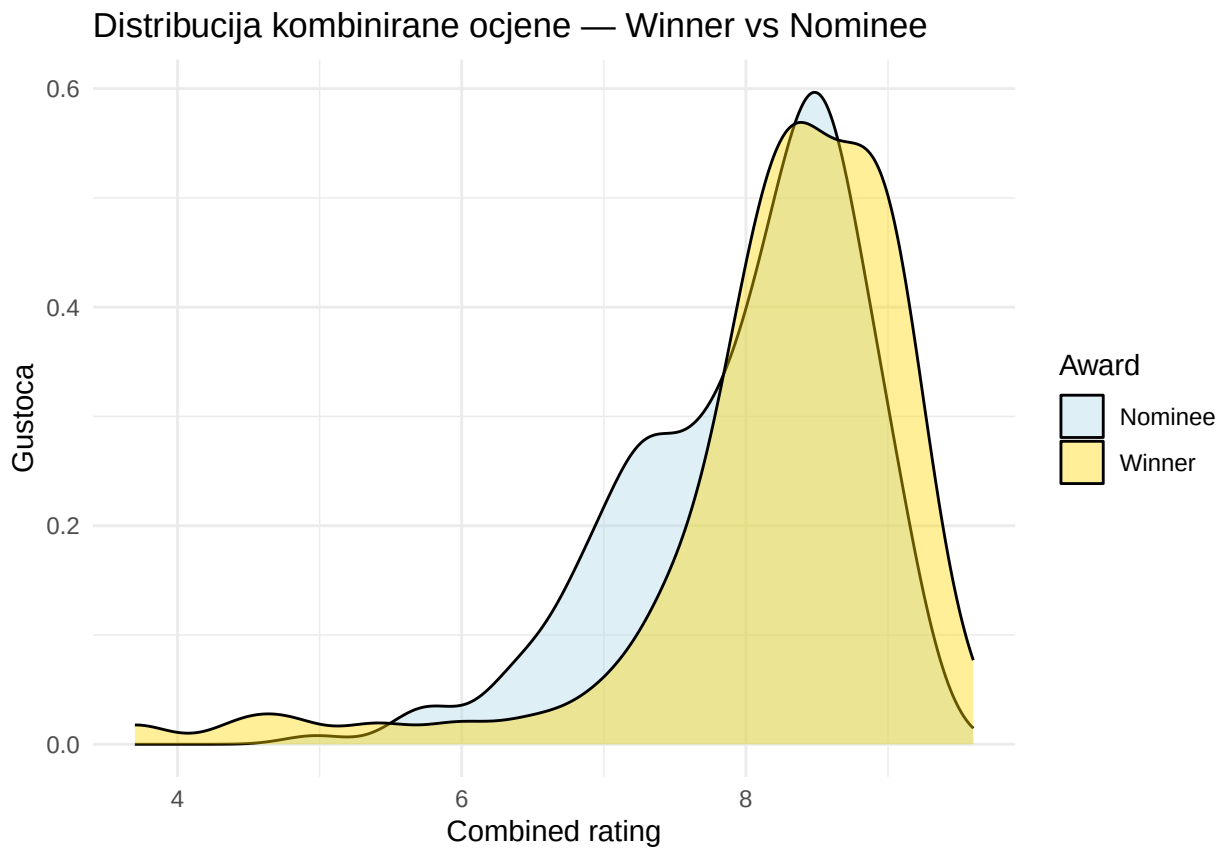
Ne možemo pretpostaviti normalnu razdiobu ocjena jer su ocjene bliže gornjim granicama. Radi toga nećemo ni pretpostaviti jednakost varijanci.

```
# Koristimo combined_rating iz 4.1
ggplot(oscars, aes(x = Award, y = combined_rating, fill = Award)) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("Winner" = "gold", "Nominee" = "lightblue")) +
  labs(
    title = "Combined rating (IMDb + RT + Audience) - Winner vs Nominee",
    x = "Status",
    y = "Combined rating (0-10)"
  ) +
  theme_minimal()
```



Boxplot nam govori da je prosjek ocjena pobjednika viši od nominiranih, ali da pobjednici imaju veću varijancu.

```
ggplot(oscars, aes(x = combined_rating, fill = Award)) +
  geom_density(alpha = 0.4) +
  scale_fill_manual(values = c("Winner" = "gold", "Nominee" = "lightblue")) +
  labs(
    title = "Distribucija kombinirane ocjene - Winner vs Nominee",
    x = "Combined rating",
    y = "Gustoća"
  ) +
  theme_minimal()
```



Density plot nam govori da je veća varijanca nominiranih, a ne pobjednika kao prije. Ponavlja se prosjek ocjena, veći je kod pobjednika nego kod nominiranih. Ovo upućuje da je možda moguće pomoću ocjena razlikovati pobjednika od nominiranih. Testirat ćemo to pomoću Wilcoxonovog rank-sum testa.

H0: raspodjele ocjena pobjednika i nominiranih su jednake

H1: raspodjele se razlikuju

Pretpostavljamo da ljudi daju podjednake ocjene na IMDb, Rotten Tomateos, itd., tj. da ocjena filmova na jednoj stranici nije značajno različita od ocjene filmova na drugoj stranici.

```
wilcox.test(combined_rating ~ Award, data = oscars)
```

```
##
##  Wilcoxon rank sum test with continuity correction
##
## data:  combined_rating by Award
## W = 17335, p-value = 0.0005057
## alternative hypothesis: true location shift is not equal to 0
```

S ovom p-vrijednosti vidimo da postoji značajna razlika u ocjenama između pobjednika i nominiranih. Odbacujemo H0.

6.1.2 Vrijeme izlaska

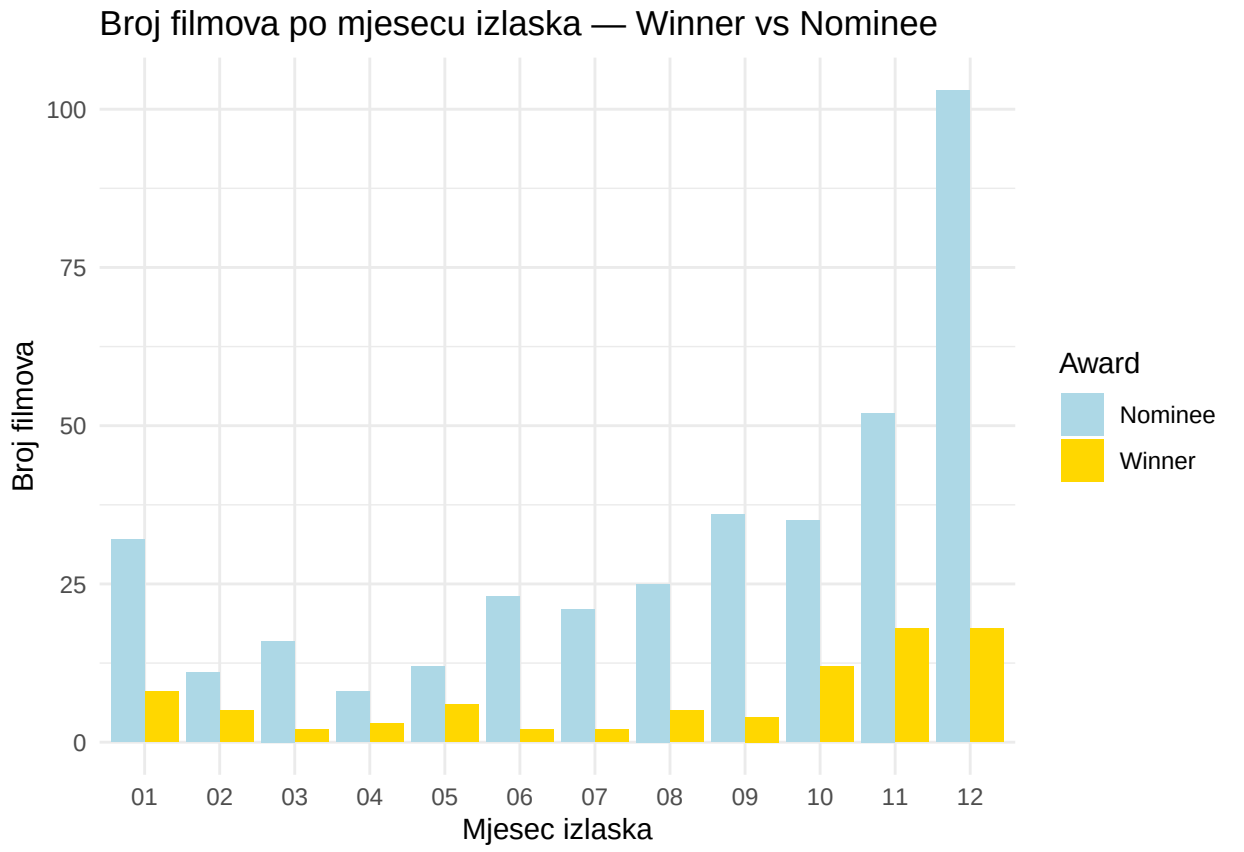
Podaci su frekvencije, a ne kontinuirane vrijednosti. Opažanja su nezavisna. Koristit ćemo χ^2 test nezavisnosti. Prikazat ćemo podatke u mjesecima, te u kvartalima po godini pa vidjeti koji izbor je bolji za χ^2 test.

H0: raspodjela mjeseci/kvartala jednaka je za pobjednike i nominirane

H1: raspodjela se razlikuje

```
oscars$Original.Release.Date <- as.Date(oscars$Original.Release.Date)
oscars$Release.Month <- format(oscars$Original.Release.Date, "%m")

ggplot(oscars[!is.na(oscars$Release.Month), ], aes(x = factor(Release.Month), fill = Award)) +
  geom_bar(position = "dodge") +
  scale_fill_manual(values = c("Winner" = "gold", "Nominee" = "lightblue")) +
  labs(
    title = "Broj filmova po mjesecu izlaska - Winner vs Nominee",
    x = "Mjesec izlaska",
    y = "Broj filmova"
  ) +
  theme_minimal()
```




```
table(oscars$Release.Month, oscars$Award)
```

```
##
##      Nominee Winner
##   01      32      8
##   02      11      5
##   03      16      2
##   04       8      3
##   05      12      6
```

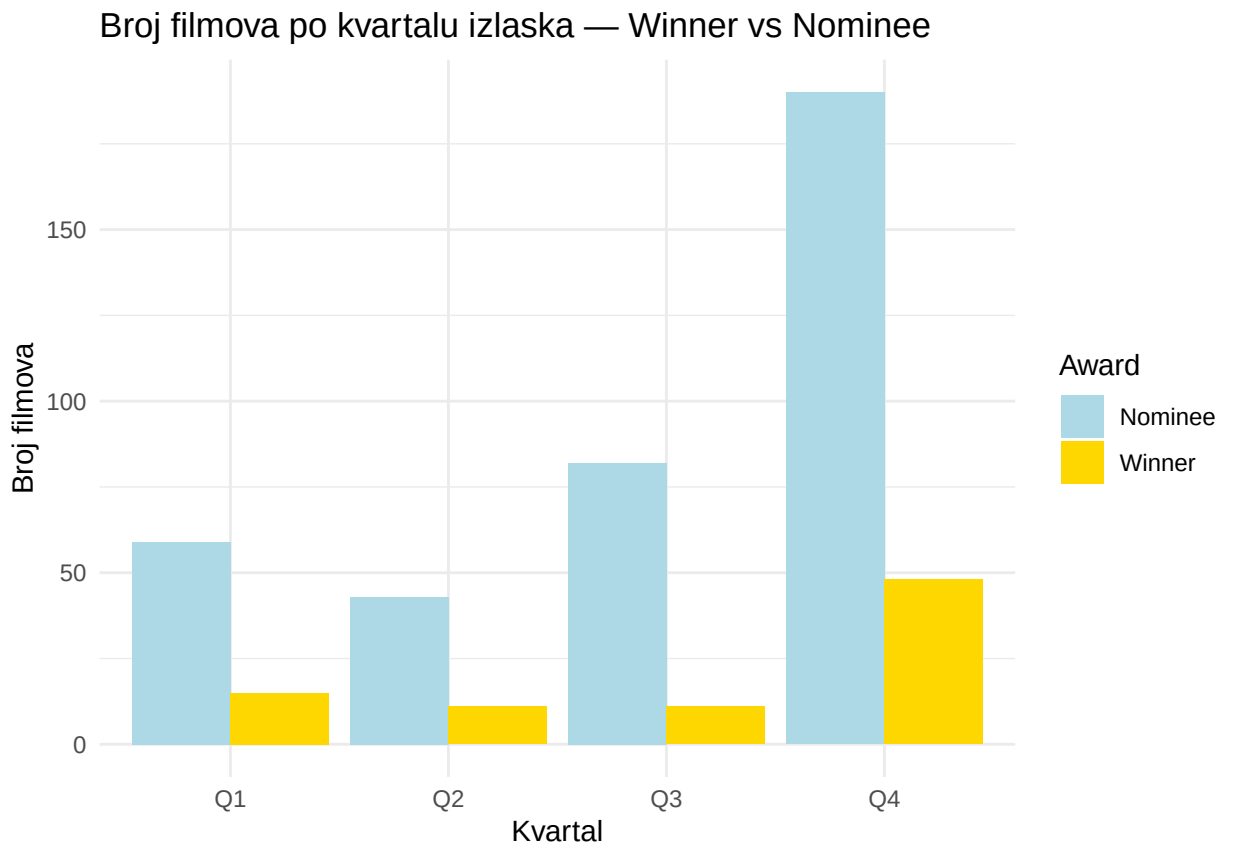
```
##   06      23       2
##   07      21       2
##   08      25       5
##   09      36       4
##   10      35      12
##   11      52      18
##   12     103      18
```

Ovo je barplot za mjesece. Uklonili smo filmove koji nisu spadali u nijedan mjesec, tako ćemo i za kvartale.

```
oscars$Release.Month <- as.numeric(format(oscars$Original.Release.Date, "%m"))

oscars$Quarter <- cut(
  oscars$Release.Month,
  breaks = c(0, 3, 6, 9, 12),
  labels = c("Q1", "Q2", "Q3", "Q4"),
  right = TRUE
)

ggplot(oscars[!is.na(oscars$Quarter), ], aes(x = factor(Quarter), fill = Award)) +
  geom_bar(position = "dodge") +
  scale_fill_manual(values = c("Winner" = "gold", "Nominee" = "lightblue")) +
  labs(
    title = "Broj filmova po kvartalu izlaska - Winner vs Nominee",
    x = "Kvartal",
    y = "Broj filmova"
  ) +
  theme_minimal()
```




```
table(oscars$Quarter, oscars$Award)
```

```
##
##      Nominee Winner
##   Q1      59     15
##   Q2      43     11
##   Q3      82     11
##   Q4     190     48
```

Ovo je barplot za kvartale.

Za testiranje ćemo koristiti kvartale, a ne mjesece jer je previše mjeseci s manje od 5 filmova. To nam već sad upućuje da vrijeme izlaska možda utječe na pobjednika te da postoji sezona 'Oscar winners' koja je u listopadu, studenom, i prosincu. Trebamo testirati jer također puno je nominiranih u to isto doba.

```
chisq.test(table(oscars$Quarter, oscars$Award))
```

```
##
##  Pearson's Chi-squared test
##
## data:  table(oscars$Quarter, oscars$Award)
## X-squared = 3.4613, df = 3, p-value = 0.3258
```

p-vrijednost nam govori da nema postoji značajna razlika kod datuma izlaska filmova među pobjednicima i nominiranima. Ne odbacujemo H0.

6.1.3 Production company

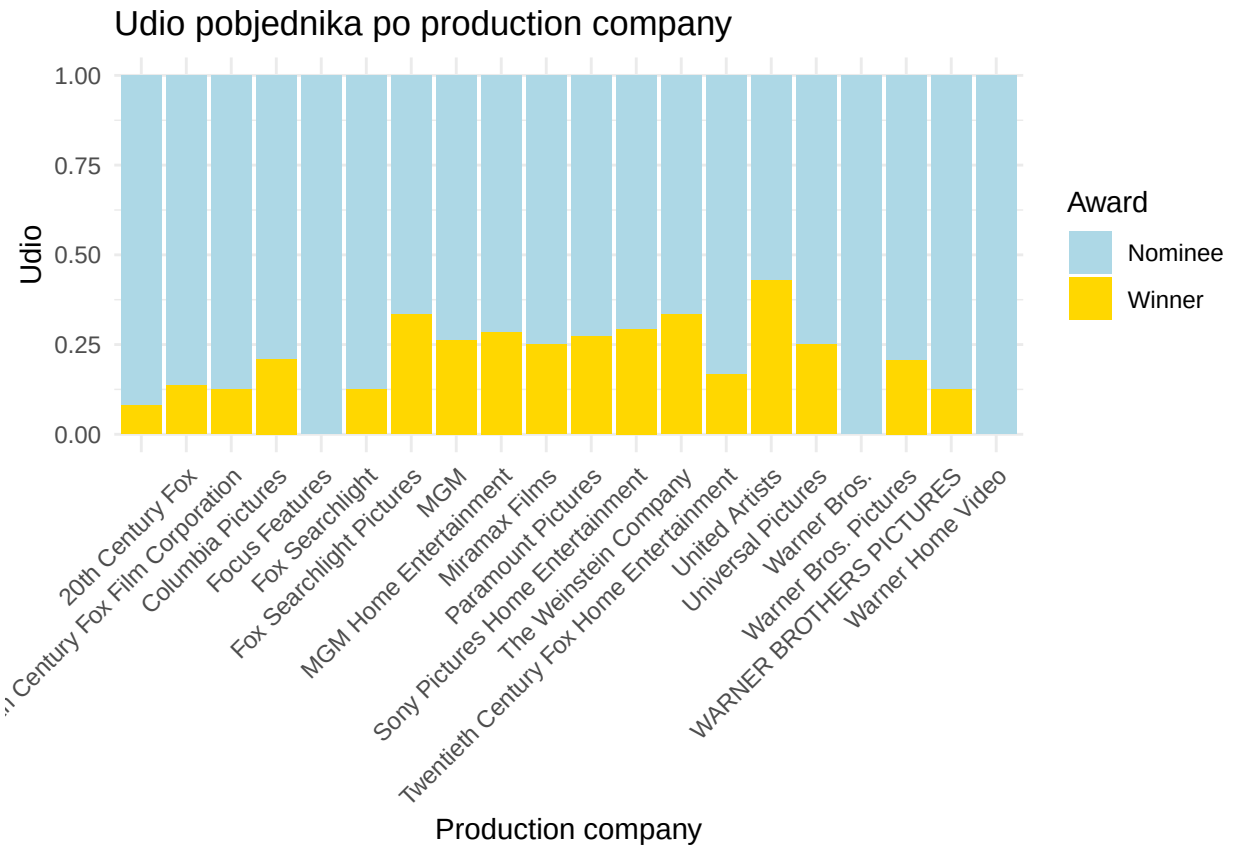
Opet ćemo koristiti χ^2 test, ovo je kategorijska varijabla. Izbacit ćemo kompanije s <5 elemenata. Kako je kroz povijest nastalo mnogo filmskih kompanija, tako ih se raspalo. Relativno puno je takvih. Njih ćemo isključiti iz testiranja jer nam mogu negativno utjecati na rezultat.

H0: raspodjela pobjednika i nominiranih jednaka je među production companies

H1: razlikuje se

```
freq <- table(oscars$Production.Company)
valid_companies <- names(freq[freq >= 5])

oscars_pc <- subset(oscars, Production.Company %in% valid_companies)
ggplot(oscars_pc, aes(x = Production.Company, fill = Award)) +
  geom_bar(position = "fill") +
  scale_fill_manual(values = c("Winner" = "gold", "Nominee" = "lightblue")) +
  labs(
    title = "Udio pobjednika po production company",
    x = "Production company",
    y = "Udio"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Postavili smo ovaj graf zato da se jasno vide udjeli pobjednika među nominiranima, tako da vidimo naslućuje li se odgovor vizualno. Ovo nam govori da raspodjela nije jednaka. Dodatna testiranja su potrebna.

```r
table(oscars_pc$Production.Company, oscars_pc$Award)
```

```
##
##                                          Nominee Winner
##                                              103      9
##   20th Century Fox                            19      3
##   20th Century Fox Film Corporation            7      1
##   Columbia Pictures                           15      4
##   Focus Features                              10      0
##   Fox Searchlight                              7      1
##   Fox Searchlight Pictures                     4      2
##   MGM                                         14      5
##   MGM Home Entertainment                      20      8
##   Miramax Films                                9      3
##   Paramount Pictures                          24      9
##   Sony Pictures Home Entertainment            12      5
##   The Weinstein Company                        4      2
##   Twentieth Century Fox Home Entertainment    15      3
##   United Artists                               8      6
##   Universal Pictures                          18      6
##   Warner Bros.                                10      0
##   Warner Bros. Pictures                       23      6
##   WARNER BROTHERS PICTURES                     7      1
##   Warner Home Video                           19      0
```

Ova tablica nije adekvatna za χ^2 test. Grupirat ćemo više manjih production companies u manje većih tako da možemo napraviti χ^2 test. One koje ne možemo grupirat ćemo izbaciti. Također ćemo izbaciti filmove bez podatka koja je njihova production company.

```r
# izbacujemo Focus i Weinstein
oscars_pc2 <- subset(
  oscars_pc,
  !(Production.Company %in% c("Focus Features", "The Weinstein Company", ""))
)
# Sad smanjujemo broj varijanti kompanija
group_company <- function(name) {
  name_lower <- tolower(name)

  if (grepl("fox", name_lower)) return("Fox")
  if (grepl("columbia", name_lower)) return("Columbia")
  if (grepl("mgm", name_lower)) return("MGM")
  if (grepl("miramax", name_lower)) return("Miramax")
  if (grepl("paramount", name_lower)) return("Paramount")
  if (grepl("sony", name_lower)) return("Sony")
  if (grepl("united artists", name_lower)) return("United Artists")
  if (grepl("universal", name_lower)) return("Universal")
  if (grepl("warner", name_lower)) return("Warner Bros")

  return("Other")
}

oscars_pc2$PC.Group <- sapply(oscars_pc2$Production.Company, group_company)
tab_groups <- table(oscars_pc2$PC.Group, oscars_pc2$Award)
```

```
tab_groups <- tab_groups[rownames(tab_groups) != "Other", ]
tab_groups
```

```
##
##                  Nominee Winner
##   Columbia            15      4
##   Fox                 52     10
##   MGM                 34     13
##   Miramax              9      3
##   Paramount           24      9
##   Sony                12      5
##   United Artists       8      6
##   Universal           18      6
##   Warner Bros         59      7
```

Sad kad imamo prikladnu tablicu možemo odraditi χ^2 test nezavisnosti.

```
chisq.test(tab_groups)
```

```
## Warning in chisq.test(tab_groups): Chi-squared approximation may be incorrect
```

```
##
##  Pearson's Chi-squared test
##
## data:  tab_groups
## X-squared = 12.115, df = 8, p-value = 0.1462
```

Zaključujemo da production company iza filma ne naslućuje je li film pobjednik.

6.2 Zaključak

Zaključujemo da su značajke koje razlikuju pobjednike od nominiranih: vrijeme trajanja, ocjene filmova.

Značajke koje ne razlikuju pobjednike od nominiranih, tj. ne postoji razlika između pobjednika i nominiranih kod tih značajki, su: žanr, redatelj, producent, vrijeme izlaska, production company.