SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 2324

ANALIZA SMJERA I TROŠKOVA ODSTUPANJA HRVATSKOG ELEKTROENERGETSKOG SUSTAVA

Luka Zorić

Zagreb, lipanj 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 2324

ANALIZA SMJERA I TROŠKOVA ODSTUPANJA HRVATSKOG ELEKTROENERGETSKOG SUSTAVA

Luka Zorić

Zagreb, lipanj 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

Zagreb, 2. ožujka 2026.

ZAVRŠNI ZADATAK br. 2324

Pristupnik:	**Luka Zorić (0036562321)**
Studij:	Elektrotehnika i informacijska tehnologija i Računarstvo
Modul:	Računarstvo
Mentor:	prof. dr. sc. Hrvoje Pandžić

Zadatak: **Analiza smjera i troškova odstupanja hrvatskog elektroenergetskog sustava**

Opis zadatka:

Zadatak obuhvaća istraživanje mehanizama nastanka odstupanja između planirane i stvarne proizvodnje te potrošnje električne energije u Republici Hrvatskoj. U radu će se analizirati regulatorni okvir i pravila obračuna odstupanja koja primjenjuje Hrvatski operator prijenosnog sustava, kao i njihova usklađenost s europskim tržišnim pravilima. Poseban naglasak stavit će se na utjecaj obnovljivih izvora energije i tržišnih sudionika na povećanje ili smanjenje troškova odstupanja. Kvantitativnom analizom dostupnih podataka procijenit će se financijski učinci odstupanja na proizvođače, opskrbljivače i krajnje kupce.

Rok za predaju rada: 12. lipnja 2026.

Zahvaljujem sljedećim osobama na njihovom trudu i suradnji:

Hrvoje Pandžić

Matko Mesar

Sažetak

Analiza smjera i troškova odstupanja hrvatskog elektroenergetskog sustava

Luka Zorić

U ovom radu analizirano je predviđanje odstupanja u elektroenergetskom sustavu primjenom linearne regresije, pri čemu je naglasak bio na poboljšanju modela kroz pažljiv odabir ulaznih značajki. Korištenjem ACF/PACF postupaka za identifikaciju bitnih vremenskih pomaka te VIF analize za uklanjanje kolinearnosti izrađen je napredni model koji na trening podacima pokazuje jasna poboljšanja u odnosu na jednostavnu linearnu regresiju i baseline pristupe. Model bolje hvata sezonalnost i kratkoročne obrasce te daje stabilnije predikcije u uvjetima koji su slični povijesnim. Ipak, rezultati na testnom danu pokazuju da linearna regresija ostaje osjetljiva na promjene obrazaca i neuobičajene događaje što dovodi do pogoršanja performansi i slabije generalizacije. Time se potvrđuje da linearni modeli s odabranim lagovima mogu biti korisni za razumijevanje strukture odstupanja i za stabilne uvjete, ali da imaju ograničenu fleksibilnost u dinamičnom elektroenergetskom okruženju.

Ključne riječi: elektroenergetski sustav; predviđanje odstupanja; linearna regresija

Abstract

Analysis of the Direction and Costs of Imbalances in the Croatian Power System

Luka Zorić

This paper analyzes the prediction of imbalances in the power system using linear regression, with the emphasis on improving the model through careful selection of input features. Using ACF/PACF procedures to identify significant time lags and VIF analysis to remove collinearity, an advanced model was created that shows clear improvements on training data compared to simple linear regression and baseline approaches. The model better captures seasonality and short-term patterns and provides more stable predictions under conditions similar to historical ones. However, the results on the test day show that linear regression remains sensitive to changes in patterns and unusual events, which leads to poor performance and poor generalization. This confirms that linear models with selected lags can be useful for understanding the structure of imbalances even under stable conditions, but have limited flexibility in a dynamic power environment.

Keywords: power system; imbalance prediction; linear regression

Sadržaj

Sažetak **1**

Abstract **2**

1. Uvod **5**

2. Funkcioniranje elektroenergetskog sustava **7**

2.1. Ravnoteža sustava i odstupanja 7

2.2. Tržište električne energije i cijene 8

2.3. Rezerve snage, njihova aktivacija te ključne komponente odstupanja . . . 10

2.4. ENTSO-E Transparency platforma 11

2.5. Izračun odstupanja sustava 12

3. Predviđanje odstupanja **14**

3.1. Cilj i pristup predviđanju odstupanja 14

3.2. Osnove strojnog učenja 15

3.3. Model linearne regresije 16

3.4. Osnovni modeli: baseline pristupi 17

3.4.1. Naivni model s lag-1 (predviđanje prema prethodnom intervalu) . 18

3.4.2. Naivni model s lag-96 (predviđanje prema istom intervalu jučer) . 20

3.5. Predviđanje jednostavnom linearnom regresijom 21

3.5.1. Priprema podataka i modela 21

3.5.2. Treniranje i evaluacija modela 22

3.5.3. Ograničenja jednostavne linearne regresije 24

3.6. Napredna linearna regresija i optimizacija lagova 24

3.6.1. Selekcija lagova 25

3.6.2. Modeli po intervalima 26
3.6.3. Predviđanje odstupanja sljedećeg dana 27
3.6.4. Usporedba s jednostavnom linearnom regresijom 28

4. Rezultati te obrada metrika 30

5. Zaključak 32

Literatura 33

Izjava o korištenju umjetne inteligencije 35

1. Uvod

Elektroenergetski sustav je složeni tehnički sustav koji biva korišten svaki dan. Većina ljudi nije ni svjesna da postoji, ali nam on osigurava da električna energija bude dostupna u svakom trenutku svakog dana u točno onim količinama koje trebaju svim korisnicima. Neki od korisnika su razna industrijska postrojenja, poduzeća, uslužne djelatnosti, privatni obrti te u konačnici mi obični potrošači. Za razliku od mnogih drugih oblika energije električna energija se ne skladišti, što znači da se proizvodnja i potrošnja moraju odvijati u gotovo savršenoj ravnoteži. Elektroenergetski sustav je vrlo osjetljiv na odstupanja (engl. Imbalance) te postoje razni mehanizmi kako bi što više moguće smanjili odstupanja. Sustav može odstupati u višak ili manjak energije, a to bilježimo u obliku smjera i volumena. Svako odstupanje između planirane i stvarne potrošnje ili proizvodnje narušava stabilnost sustava, a posljedice mogu biti povećani troškovi, aktivacija skupih rezervi, pa u ekstremnim slučajevima i poremećaji u radu elektroenergetske mreže.

Upravo zato operatori prijenosnih sustava, poput hrvatskog HOPS-a, kontinuirano nadziru stanje sustava i brinu o održavanju ravnoteže između proizvodnje i potrošnje. Kada dođe do odstupanja, sustav reagira aktivacijom različitih vrsta rezervi, počevši s primarnom rezervom (FCR), zatim s automatskom sekundarnom rezervom (aFRR), preko ručne sekundarne rezerve (mFRR), pa sve do kapacitetnih rezervi koje se ugovaraju unaprijed. Svaka od ovih rezervi ima svoju cijenu koju odgovorni subjekti snose.

Javno su dostupni podaci vezani za elektroenergetski sustav te je sustav transparentan. Transparentnost je uspostavljena kroz standardiziranje pristupa podacima o svim elektroenergetskim sustavima u Europi putem platforme ENTSO-E Transparency[1]. Na toj platformi su objedinjeni podaci svih europskih operatora prijenosnih sustava. Tamo se nalaze podaci od velike važnosti za odstupanje poput aktiviranih rezervi, cijena akti-

viranih rezervi te volumen i smjer samog odstupanja. Ti podaci su nam temelj za analizu i modeliranje ponašanja sustava te za razvoj metoda predviđanja odstupanja.

Predviđanje odstupanja elektroenergetskog sustava važno je kako bi se uklonile poteškoće prilikom odstupanja te kako bi se osigurao siguran i nesmetan prijenos električne energije od svakog proizvođača i dobavljača do svakog korisnika i potrošača. Preciznije prognoze odstupanja omogućile bi operatorima i tržišnim sudionicima bolje planiranje, smanjenje troškova i sigurniji rad sustava.

Cilj rada je istražiti je li moguće unaprijed predvidjeti odstupanje sustava na temelju povijesnih podataka dostupnih na ENTSO-E Transparency platformi[1]. Opisuje se način funkcioniranja elektroenergetskog sustava, mehanizmi održavanja ravnoteže te podaci koji se koriste za razumijevanje i izračun odstupanja. Predstavljene su metode predviđanja i njihova implementacija, obrada njihovih rezultata i što ti rezultati znače za dotični model i za daljnji rad. Analizom i usporedbom svih rezultata uspoređuju se različiti modeli te se na kraju iznose zaključci.

2. Funkcioniranje elektroenergetskog sustava

2.1. Ravnoteža sustava i odstupanja

Elektroenergetski sustav temelji se na načelu da se proizvodnja i potrošnja električne energije moraju u svakom trenutku nalaziti u ravnoteži. Električna energija se ne može skladištiti zbog čega se svaka promjena potrošnje mora gotovo trenutačno kompenzirati odgovarajućom promjenom proizvodnje. Kada je sustav u ravnoteži, frekvencija elektroenergetske mreže stabilno se održava oko stabilne vrijednosti od 50 Hz. Svako odstupanje od te vrijednosti ukazuje na neravnotežu između proizvodnje i potrošnje.

Odstupanje sustava, odnosno imbalance, nastaje kada se stvarna proizvodnja ili potrošnja razlikuje od unaprijed planirane. Ako je potrošnja veća od proizvodnje, nastaje negativno odstupanje, dok pozitivno odstupanje označava situaciju u kojoj je proizvodnja veća od potrošnje. Obje situacije narušavaju stabilnost sustava i zahtijevaju intervenciju operatora prijenosnog sustava. Odstupanje se opisuje kroz dva parametra: smjer odstupanja i volumen odstupanja, pri čemu smjer označava radi li se o višku ili manjku energije, a volumen predstavlja veličinu odstupanja izraženu u MWh.

Za održavanje ravnoteže odgovoran je operator prijenosnog sustava, u Hrvatskoj HOPS, koji stalno nadzire stanje mreže i aktivira odgovarajuće mehanizme za uklanjanje odstupanja. Kada dođe do neravnoteže, sustav reagira aktivacijom različitih vrsta rezervi, počevši od primarne rezerve (FCR), preko automatske sekundarne rezerve (aFRR) te ručne sekundarne rezerve (mFRR). Aktivacija rezervi omogućuje vraćanje sustava u ravnotežu, ali istovremeno generira trošak koji se naplaćuje subjektima odgovornima za odstupanje, najčešće opskrbljivačima ili bilančnim grupama.

Postoje tržišta električne energije koja koriste tržišne cijene, poput day-ahead cijena,

kako bi se odredila financijska posljedica odstupanja. U trenucima velikih neravnoteža cijene odstupanja mogu biti značajno drukčije od onih na jučerašnjem day ahead tržištu.

2.2. Tržište električne energije i cijene

Tržište električne energije predstavlja skup mehanizama, pravila i sudionika koji omogućuju kupnju i prodaju električne energije. Postoji specifičnost vezana za tržište električne energije, a to je da se električna energija mora isporučiti u trenutku kada se proizvede, što znači da se tržišni procesi moraju odvijati brzo, precizno i uz stalnu koordinaciju svih sudionika.

Tržište se najčešće dijeli na nekoliko vremenskih razina. Najvažnije među njima je day-ahead tržište, na kojem se električna energija kupuje i prodaje dan unaprijed, u 15-minutnim intervalima. Sudionici su proizvođači, dobavljači, agregatori i veliki potrošači koji predaju svoje ponude i potražnje, a tržišni operator određuje ravnotežnu cijenu za svaki interval sljedećeg dana. Ova cijena predstavlja referentnu vrijednost prema kojoj se planira proizvodnja i potrošnja. Day-ahead tržište je temelj planiranja za sudionike jer određuje očekivane troškove i prihode za sljedeći dan. Energija na day-ahead tržištu se obračunava isto kao i odstupanje, a to je u EUR/MWh.

Ipak, stvarna potrošnja i proizvodnja često odstupaju od planiranih vrijednosti. Zbog toga postoji intraday tržište, koje omogućuje trgovanje električnom energijom unutar samog dana, sve do nekoliko minuta prije isporuke. Intraday tržište služi za korekciju planova i smanjenje potencijalnih odstupanja. Sudionici koji uoče da će odstupiti od plana mogu kupiti ili prodati dodatnu energiju kako bi smanjili rizik od financijskih posljedica. Cijene na intraday tržištu često su volatilnije od day-ahead cijena jer odražavaju trenutačne uvjete u sustavu. Cijene se, radi nepredvidivosti i neplaniranih kupnji, mogu znatno razlikovati od cijena na day ahead tržištu.

Unatoč postojanju više tržišnih mehanizama, odstupanja se ne mogu u potpunosti izbjeći. Kada se dogode, operator prijenosnog sustava aktivira rezerve kako bi ponovno uspostavio ravnotežu. Aktivacija rezervi ima svoju cijenu, a ta se cijena prenosi na subjekte koji su odstupanje uzrokovali. Ovdje se uvodi pojam cijene odstupanja, koja može biti viša ili niža od tržišnih cijena, ovisno o stanju sustava. Ako je sustav u manjku ener-

gije, cijena odstupanja obično je visoka jer je potrebno aktivirati skupe pozitivne rezerve. Ako je sustav u višku, cijena odstupanja može biti niska ili čak negativna, što odražava višak proizvodnje koji treba apsorbirati. Nižom cijenom se potiče sudionike potrošače da kupe električnu energiju pri nižoj cijeni i potroše je tako da se višak energije ukloni iz sustava trošenjem. Viša cijena se javlja kada je manjka energije u sustavu te se time kažnjava sudionike tako što su prekoračili količinu koju su naručili. U specifičnim situacijama je moguće da je cijena negativna, tj. da sudionici dobivaju novce za preuzimanje električne energije kada je iznimno velik višak energije u sustavu. Jedan primjer kada je iznimno velik višak energije u sustavu je ako potrošnja bude niža od očekivane, a proizvođači, npr. solarne elektrane i vjetroelektrane proizvedu više nego što su predviđale da će proizvesti.

Važno je naglasiti da se trošak odstupanja ne naplaćuje krajnjim potrošačima, već odgovornim subjektima, a to su najčešće opskrbljivačima ili bilančnim grupama. Oni su dužni planirati svoju potrošnju i proizvodnju te snositi financijske posljedice ako odstupanje nastane.

Ukoliko je manjak energije u sustavu, a subjekt potroši manje energije nego što je naručio na jučerašnjem day ahead tržištu bude nagrađen tako što mu troškovi budu manji nego da je naručio istu količinu koju je potrošio. Ako je manjak energije, a subjekt potroši više nego što je naručio bit će kažnjen tako što će imati veće troškove, tj. veću cijenu plaćanja dodatne električne energije koju je potrošio. Također, ako je višak energije u sustavu, a subjekt potroši više nego što je naručio na day ahead tržištu bit će nagrađen tako što će cijena dodatne električne energije biti manja. Ako je višak energije, a subjekt potroši manje nego što je naručio bit će kažnjen s nepovoljnom cijenom odstupanja. Cijena odstupanja za vrijeme viška energije u sustavu se označava s C_{EU-}, dok se cijena odstupanja za vrijeme manjka energije u sustavu označava s C_{EU+}. Jasno je vidljiva mehanika smjera plaćanja u tablici 2.1. [2].

	Imbalance price positive	**Imbalance price negative**
Positive imbalance	Payment from TSO to BRP	Payment from BRP to TSO
Negative imbalance	Payment from BRP to TSO	Payment from TSO to BRP

Tablica 2.1. Odstupanje - smjer plaćanja; TSO-operator prijenosnog sustava (npr. HOPS), BRP-sudionik tržišta

2.3. Rezerve snage, njihova aktivacija te ključne komponente odstupanja

Stabilnost elektroenergetskog sustava ovisi o sposobnosti operatora prijenosnog sustava da u svakom trenutku uravnoteži proizvodnju i potrošnju. Budući da se električna energija ne može skladištiti, sustav mora imati mehanizme koji omogućuju trenutnu reakciju na odstupanja. Ti mehanizmi nazivaju se rezerve snage, a njihova aktivacija predstavlja ključ za održavanje ravnoteže. Rezerva snage se ugovori na day-ahead tržištu između HOPS-a i nekog opskrbljivača.

Rezerve snage dijele se prema brzini reakcije i načinu aktivacije. Primarna rezerva (FCR) aktivira se automatski i trenutačno, u roku od nekoliko sekundi, kao odgovor na promjenu frekvencije. Ona služi za stabilizaciju frekvencije i sprječavanje daljnjeg pogoršanja odstupanja. Nakon nje djeluje automatska sekundarna rezerva (aFRR), koja se aktivira putem automatiziranog sustava i preuzima ulogu vraćanja frekvencije prema stabilnoj vrijednosti. Ako odstupanje potraje ili je potrebno dodatno uravnoteženje, aktivira se ručna sekundarna rezerva (mFRR), kojom ručno upravlja operator prijenosnog sustava.

Svaka od ovih rezervi može biti aktivirana u pozitivnom ili negativnom smjeru. Pozitivna aktivacija znači povećanje proizvodnje ili smanjenje potrošnje, dok negativna aktivacija znači smanjenje proizvodnje ili povećanje potrošnje. Postoji osam komponenti koje su ključne pri izračunavanju cijene troškova nastalih aktiviranjem ovih rezervi snage. Aktivacije se bilježe u obliku tih osam ključnih komponenti koje se koriste za izračun odstupanja sustava [3]. Te komponente su:

E_{aFRR+} – pozitivna energija automatske sekundarne rezerve

E_{aFRR-} – negativna energija automatske sekundarne rezerve

E_{mFRR+} – pozitivna energija ručne sekundarne rezerve

$E_{\mathrm{mFRR}-}$ – negativna energija ručne sekundarne rezerve

C_{aFRR+} – cijena pozitivne energije automatske sekundarne rezerve

C_{aFRR-} - cijena negativne energije automatske sekundarne rezerve

C_{mFRR+} – cijena pozitivne energije ručne sekundarne rezerve

C_{mFRR-} – cijena negativne energije ručne sekundarne rezerve

Energijske komponente predstavljaju stvarno aktiviranu energiju rezervi, dok cijene aktiviranih energija predstavljaju cijenu svake aktivirane energije. Aktivirana energije se bilježi u MWh dok se cijena bilježi u Eur/MWh. Varijable koje imaju '+' u svom imenu ukazuju na potrebu za dodatnom energijom u sustavu, tj. da ima manjka energije u sustavu dok varijable koje imaju '-' u svom imenu ukazuju na višak energije koji treba smanjiti. Kombinacijom ovih osam komponenti moguće je precizno odrediti smjer i volumen odstupanja sustava u svakom vremenskom intervalu.

Aktivacija rezervi ima i financijsku dimenziju. Svaka aktivacija nosi određeni trošak, a taj se trošak prenosi na subjekte koji su odstupanje uzrokovali.

2.4. ENTSO-E Transparency platforma

ENTSO-E Transparency platforma [1] predstavlja centralno mjesto za prikupljanje, objavu i standardizaciju podataka o elektroenergetskim sustavima svih europskih operatora prijenosnih sustava. Platforma je uspostavljena kako bi se osigurala transparentnost, ujednačenost podataka i jednak pristup informacijama svim sudionicima tržišta električne energije. Ova platforma omogućuje pružanje potrebnih informacija o tržištu električne energije za budućnost i dodatno olakšava razvoj učinkovitih i konkurentnih energetskih tržišta diljem Europe. Takva platforma potiče stalan razvoj tržišta električne energije diljem Europe u smislu integracije i konkurencije. [4]

Platforma je strukturirana tako da pokriva širok spektar podataka, poput proizvodnje električne energije, potrošnju, rezervirane snage, tržišne cijene, aktivacije rezervi i odstupanja sustava. Za potrebe ovog rada najvažniji su podaci iz područja balansiranja sustava, jer upravo oni omogućuju izračun odstupanja i analizu ponašanja elektroenergetskog sustava u stvarnom vremenu. ENTSO-E Transparency platforma objavljuje podatke u standardiziranom formatu, što omogućuje jednostavnu obradu i usporedbu podataka između različitih zemalja i vremenskih razdoblja.

Jedna od ključnih prednosti platforme je to što pruža povijesne i gotovo real-time podatke, čime omogućuje detaljnu analizu dinamike sustava. Unutar nekoliko dana podaci bivaju objavljeni na platformi. Podaci o aktiviranim rezervama, cijenama odstupanja i smjeru odstupanja objavljuju se u intervalima od 15 minuta ili jednog sata, ovisno o državi i vrsti podatka. Time se dobiva uvid u to kako sustav reagira na promjene u proizvodnji i potrošnji te kako operatori prijenosnih sustava koriste rezerve za održavanje ravnoteže.

Za izračun odstupanja sustava koriste se osam ključnih komponenti aktiviranih rezervi, koje platforma objavljuje u sklopu sekcije o balansiranju. Te komponente uključuju pozitivne i negativne aktivacije automatske sekundarne rezerve (aFRR) te ručne sekundarne rezerve (mFRR). Svaka od ovih komponenti predstavlja određeni oblik intervencije operatora sustava i zajedno daju potpunu sliku o tome kako je sustav reagirao na odstupanje.

ENTSO-E Transparency platforma također objavljuje cijene aktiviranih rezervi i cijene odstupanja, što omogućuje analizu ekonomske strane balansiranja sustava. U trenucima velikih neravnoteža cijene odstupanja mogu biti vrlo visoke ili čak negativne, što odražava stanje sustava i trošak aktivacije rezervi. Ovi podaci ključni su za razumijevanje financijskih posljedica odstupanja i za procjenu učinkovitosti modela predviđanja.

Platforma je dizajnirana tako da bude dostupna svima, od operatora sustava i tržišnih sudionika do istraživača i akademske zajednice. Svi podaci mogu se preuzeti putem web sučelja ili API-ja [5], što omogućuje automatizirano prikupljanje i obradu velikih količina podataka. U kontekstu ovog rada, ENTSO-E Transparency platforma predstavlja primarni izvor podataka za analizu odstupanja i za razvoj modela predviđanja, jer pruža pouzdane, standardizirane i detaljne informacije o radu elektroenergetskog sustava.

2.5. Izračun odstupanja sustava

Cijena odstupanja se u Hrvatskoj računa po modelu od jedne cijene (engl. single pricing scheme). U nekim državama se koristi model od dvije cijene (engl. dual pricing scheme). Razlika između ova dva modela je što se kod modela od jedne cijene nagrađuje odstupanje koje pomaže sustavu, tj. ono odstupanje koje približava sustav ravnoteži. Npr. kad je

višak energije u sustavu, a subjekt potroši više nego što je naručio. Kod modela od dvije cijene se ne nagrađuje odstupanje koje pomaže sustave. Zajedničko im je kažnjavanje subjekata koji nepovoljno utječu na sustav, tj. udaljuju sustav od ravnoteže.

Cijena se računa tako da prvo vidimo je li sustav u jednom od tri stanja [3]:

- višak energije (engl. surplus): Imbalance > 0, cijena je C_{EU-}
- stanje ravnoteže: Imbalance $= 0$, cijena je C_{EU0}
- manjak ravnoteže (engl. deficit): Imbalance < 0, cijena je C_{EU+}

Ukoliko je sustav u stanju ravnoteže onda je cijena električne energije C_{EU0} za dotični interval ista kao što je bila na jučerašnjem day-ahead tržištu.

Ako sustav ima višak energije, cijenu $C_{EU-,i}$, gdje i označava dotični interval, za svaki interval i računamo na sljedeći način [3]:

$$C_{EU-,i} = \frac{E_{aFRR-,i}\, C_{aFRR-,i} + E_{mFRR-,i}\, C_{mFRR-,i}}{E_{aFRR-,i} + E_{mFRR-,i}}$$

Ako sustav ima manjak energije, cijenu $C_{EU+,i}$ računamo na sljedeći način:

$$C_{EU+,i} = \frac{E_{aFRR+,i}\, C_{aFRR+,i} + E_{mFRR+,i}\, C_{mFRR+,i}}{E_{aFRR+,i} + E_{mFRR+,i}}$$

3. Predviđanje odstupanja

3.1. Cilj i pristup predviđanju odstupanja

Predviđanje odstupanja odnosi se na procjenu budućeg smjera i volumena odstupanja, tj. razlike između planirane i stvarne razlike u proizvodnji i potrošnji. U elektroenergetskom sustavu, u kojem se električna energija ne može skladištiti, odstupanja predstavljaju izravni operativni i financijski rizik. To znači da precizno predviđanje odstupanja omogućuje smanjenje troškova aktivacije rezervi te stabilniji rad sustava.

Predviđanje odstupanja posebno je izazovno zbog više razloga. Prvo, odstupanja su izrazito volatilna, s naglim skokovima uzrokovanim promjenama u proizvodnji iz obnovljivih izvora, neočekivanim promjenama potrošnje ili aktivacijama rezervi. Drugo, pokazuje nelinearnost. Odnosi između prošlih i budućih odstupanja nisu jednostavni, a utjecaj pojedinih vremenskih intervala može biti različit ovisno o dobu dana. Treće, prisutna je sezonalnost na više razina: dnevna koja se očituje u različitim obrascima potrošnje, tjedna u smislu radnih dana i vikenada te sezonska u obliku zime i ljeta. Zbog toga je potrebno koristiti modele koji mogu iskoristiti strukturu podataka, ali i da budu dovoljno fleksibilni da se nose s neregularnostima.

Podaci korišteni u ovom radu preuzeti su s ENTSO-E Transparency platforme [2], a sastoje se od smjera i volumena odstupanja sustava. Podaci su dostupni u 15-minutnim intervalima, što znači da se za svaki dan dobiva 96 intervala. Za predviđanje svakog od tih intervala koristimo povijesne vrijednosti odstupanja, organizirane u obliku lagova. Lag predstavlja vrijednost odstupanja iz prošlosti, udaljenu za određeni broj intervala. Na primjer, lag-1 označava odstupanje iz prethodnog intervala, lag-96 odstupanje iz istog intervala prethodnog dana, a lag-192 odstupanje iz istog intervala prije dva dana. Ovi lagovi služe kao ulazne značajke modela i omogućuju mu da uči obrasce u dinamici

sustava.

Međutim, korištenje lagova nije trivijalno. Zbog pravila dostupnosti podataka, ne mogu se koristiti svi lagovi za sve intervale. Ako se prognoza pokreće u 07:00, tada su dostupni samo oni lagovi čiji vremenski prozor završava prije trenutka pokretanja prognoze, tj. lag je dostupan samo ako mu gornja granica pada strogo prije trenutka pokretanja prognoze. To znači da se skup dostupnih lagova mijenja ovisno o tome koji interval predviđamo.

Pristup predviđanju u ovom radu temelji se na kombinaciji baseline modela, osnovne linearne regresije i napredne linearne regresije. Baseline modeli služe kao referentna točka jer su jednostavni, ali omogućuju procjenu koliko je napredniji model zaista bolji. Osnovna linearna regresija koristi dostupne lagove bez dodatne optimizacije, dok napredna verzija uvodi selekciju lagova, modele po intervalima i precizno upravljanje dostupnošću podataka. Time se postiže veća točnost i stabilnost predviđanja.

3.2. Osnove strojnog učenja

Strojno učenje predstavlja područje računarstva koje omogućuje računalnim modelima da uče obrasce iz podataka i na temelju njih donose predikcije ili odluke. Za razliku od klasičnog programiranja, gdje se pravila i odnosi među varijablama eksplicitno definiraju, u strojnom učenju model sam pronalazi odnose među varijablama. U kontekstu predviđanja odstupanja elektroenergetskog sustava, strojno učenje omogućuje modelu da iz povijesnih odstupanja prepozna obrasce koji se ponavljaju te ih iskoristi za procjenu budućih vrijednosti.

Za predviđanje odstupanja koristi se nadzirano učenje. Model uči iz parova ulaz-izlaz, što znači da za svaki ulazni primjer postoji poznata ciljna vrijednost. Strojno učenje koristi se za učenje odnosa između prošlih odstupanja (lagova) i budućih vrijednosti. Lagovi predstavljaju vremenski pomaknute vrijednosti odstupanja, npr. odstupanje iz prethodnog intervala, iz istog intervala prethodnog dana ili iz istog intervala prije dva dana. Model uči kako kombinacija tih prošlih vrijednosti utječe na odstupanje koje tek dolazi.

Predviđanje odstupanja predstavlja izazovan zadatak zbog volatilnosti, sezonalnosti

i nelinearnosti podataka te same nepredvidivosti elektroenergetskog sustava, ali strojno učenje omogućuje izgradnju modela koji se mogu prilagoditi tim obrascima. Linearna regresija je jedna metoda koja je pogodna za analizu i predviđanje odstupanja jer se vidi jasna veza između intervala koje predviđamo te koji prošli intervali su najviše povezani s dotičnim intervalom.

3.3. Model linearne regresije

Linearna regresija se razvila iz potrebe da se matematički opišu odnosi među veličinama koje se mijenjaju kroz vrijeme i prostor. Prvi tragovi javljaju se kod Adriena-Marieja Legendrea i Carla Friedricha Gaussa početkom 19. stoljeća, kada su razvili metodu najmanjih kvadrata za preciznije određivanje orbitalnih putanja nebeskih tijela [6]. Tijekom 19. i 20. stoljeća linearna regresija postaje standardni alat u statistici, ekonomiji i biologiji, gdje se koristila za modeliranje rasta populacija, ekonomskih trendova i fizičkih zakonitosti. U modernom strojnome učenju linearna regresija ostaje temeljni model: jednostavna je, interpretabilna i služi kao početna točka za razumijevanje složenijih metoda.

Linearni modeli predstavljaju jednu od najjednostavnijih, ali i najšire korištenih metoda u području nadziranog učenja. Njihova osnovna ideja je da se ciljna varijabla može opisati linearnom kombinacijom ulaznih značajki, pri čemu se svaki ulaz množi pripadajućim koeficijentom koji određuje njegov doprinos predikciji. U kontekstu predviđanja odstupanja elektroenergetskog sustava, linearni modeli omogućuju nam da procijenimo kako se prošla odstupanja (lagovi) odražavaju na buduće vrijednosti.

Linearni model pretpostavlja da se buduća vrijednost odstupanja može zapisati kao zbroj izmijenjenih prošlih vrijednosti. Matematički oblik linearne regresije poprima sljedeći izgled [7]:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n$$

U ovom radu ulazne značajke $x_1, x_2, \ldots, x_n$ predstavljaju lagove, odnosno vrijednosti odstupanja iz prethodnih vremenskih intervala. Na primjer, lag-1 označava odstupanje

iz prethodnog 15-minutnog intervala, lag-96 odstupanje iz istog intervala kao onaj koji predviđamo samo iz prethodnog dana, a lag-192 odstupanje iz istog intervala prije dva dana. Time linearna regresija postaje alat koji prepoznaje autokorelaciju, odnosno vezu između trenutnih odstupanja i njihovih ranijih vrijednosti.

Koeficijenti linearne regresije imaju jasnu interpretaciju:

- pozitivan koeficijent znači da veća vrijednost pripadajućeg laga pomiče predikciju u istom smjeru kao i taj lag (prema većem pozitivnom odstupanju ili prema većem negativnom odstupanju)
- negativan koeficijent znači da veća vrijednost laga pomiče predikciju u suprotnom smjeru (smanjuje pozitivno odstupanje ili povećava negativno odstupanje)
- apsolutna vrijednost koeficijenta pokazuje koliki je relativni utjecaj pojedinog laga na predikciju

Ova interpretabilnost čini linearne modele posebno korisnima u energetici, gdje je važno razumjeti zašto model daje određenu predikciju, a ne samo što predviđa. Koeficijenti i lagovi nam daju jasniju sliku i uvid u načine ostvarivanja predikcije.

Linearni modeli dobro funkcioniraju kada je odnos između prošlih i budućih vrijednosti približno linearan. Međutim, odstupanja elektroenergetskog sustava karakteriziraju i nagli skokovi, nelinearnosti i sezonalni obrasci. Zbog toga linearna regresija pruža zanimljivu sliku o predikcijama u području koje je djelomično linearno.

3.4. Osnovni modeli: baseline pristupi

Baseline modeli predstavljaju najjednostavnije moguće pristupe predviđanju i služe kao referentna točka za procjenu kvalitete naprednijih modela. Njihova je uloga pokazati koliko dobro možemo predvidjeti odstupanje bez ikakvog učenja kompleksnih obrazaca, koristeći samo trivijalne informacije iz prošlosti. Ako napredni modeli ne uspiju nadmašiti baseline, to znači da nisu dovoljno učinkoviti.

Koristimo dva osnovna baseline modela, oba temeljena na jednoj ulaznoj varijabli. Baseline modeli su lag-1 i lag-96. Ovi modeli su jednostavni, ali vrlo informativni jer isko-

rištavaju relativno jednostavne značajke kao što su kratkoročna autokorelacija i dnevna sezonalnost.

3.4.1. Naivni model s lag-1 (predviđanje prema prethodnom intervalu)

Prvi baseline model koristi vrijednost odstupanja iz prethodnog 15-minutnog intervala kao predikciju za sljedeći interval. Ideja je jednostavna: ako se sustav ne mijenja naglo, tada je najnovija vrijednost najbolji prediktor buduće. Poprima sljedeći matematički oblik:

$$y_t = y_{t-1}$$

Ovaj model je posebno koristan jer mjeri kratkoročnu stabilnost vremenske serije. Ako odstupanja imaju snažnu autokorelaciju, lag-1 model može postići iznenađujuće dobre rezultate.

U nastavku se mogu prikazati metrike modela:

Metric	Value
Mean	-4.526443101850263
Std	22.925235467066273
Median	-4.646
Min	-107.37
Max	139.549
MAE	10.130113556005629
RMSE	14.258094820826281
MAPE	381.64466555493686
sMAPE	0.8263838053473036
$MASE_1$	–
$MASE_{96}$	1.0635674399412114
R^2	0.6131818526207347

Tablica 3.1. Metrike naivnog modela (lag-1)

Objašnjenje metrika:

- MAE (Mean Absolute Error) - prosječna apsolutna pogreška; govori koliko se, u prosjeku, predikcija razlikuje od stvarne vrijednosti u apsolutnom iznosu.

- RMSE (Root Mean Squared Error) - korijen srednje kvadratne pogreške; jače kažnjava velike pogreške i osjetljiv je na nagle skokove.
- MAPE (Mean Absolute Percentage Error) - prosječna relativna pogreška izražena u postocima; nepouzdana je kada su stvarne vrijednosti blizu nule.
- sMAPE (Symmetric MAPE) - simetrična verzija MAPE-a koja ublažava ekstremne vrijednosti i stabilnija je kod podataka koji često prelaze kroz nulu.
- MASE (Mean Absolute Scaled Error) - pogreška skalirana u odnosu na referentni (naivni) model;
- MASE_1 uspoređuje model s lag-1 baseline-om,
- MASE_{96} uspoređuje model s lag-96 baseline-om.
- R^2 - koeficijent determinacije; pokazuje koliki dio varijance podataka model objašnjava.

Objašnjenje brojki iz tablice:

- MAE je 10.13 - Model u prosjeku griješi oko 10 MWh po intervalu, što je očekivano za jednostavan naivni pristup.
- RMSE je 14.26 - Veća vrijednost od MAE-a pokazuje da postoje povremeni veliki skokovi odstupanja koje model ne uspijeva uhvatiti.
- MAPE je 381% - Ova vrijednost je vrlo visoka jer se odstupanja često približavaju nuli; čak i mala apsolutna pogreška daje ogroman postotak.
- sMAPE je 0.826 - Realnija mjera od MAPE-a, pokazuje da je prosječna relativna pogreška oko 82.6%, što je tipično za volatilne vremenske serije.
- MASE_1 nije određen - Ne može se uspoređivati sam sa sobom.
- MASE_{96} je 1.06 - Model je samo malo lošiji od dnevnog sezonskog baseline-a, što potvrđuje da dnevna sezonalnost ima snažan utjecaj.
- R^2 je 0.613 - Model objašnjava oko 61% varijance odstupanja - solidno za jednosta-

van naivni pristup, ali daleko od optimalnog.

3.4.2. Naivni model s lag-96 (predviđanje prema istom intervalu jučer)

Drugi baseline model koristi vrijednost odstupanja iz istog intervala prethodnog dana. Budući da se potrošnja i proizvodnja električne energije često ponavljaju u dnevnim ciklusima, ovaj model iskorištava dnevnu sezonalnost. Matematički zapis modela poprima sljedeći oblik:

$$y_t = y_{t-96}$$

Ovaj model je posebno važan jer pokazuje koliko je snažna dnevna struktura odstupanja. Ako lag-96 baseline daje dobre rezultate, to znači da sustav ima stabilne dnevne obrasce; ako ne, sustav je izrazito nestabilan ili pod utjecajem vanjskih faktora.

U nastavku se mogu prikazati metrike modela:

Metric	**Value**
Mean	-4.542938696790191
Std	22.952246257000766
Median	-4.6705
Min	-107.37
Max	139.549
MAE	22.377740907838543
RMSE	29.398330822863265
MAPE	768.1154566590478
sMAPE	1.3327074378574715
$MASE_1$	2.348478106937182
$MASE_{96}$	–
R^2	-0.6448145055544481

Tablica 3.2. Metrike naivnog modela (lag-96)

Rezultati naivnog modela s lag-96 pokazuju bitno drukčije ponašanje u odnosu na lag-1 baseline. Prvo, MAE = 22.38 i RMSE = 29.40 gotovo su dvostruko veći nego kod lag-1 modela, što znači da je predviđanje prema istom intervalu jučer znatno manje precizno od predviđanja prema prethodnom intervalu. To je očekivano jer dnevna sezonalnost postoji, ali je slabija od kratkoročne autokorelacije. Sustav se u kratkom roku

mijenja sporije nego u razmaku od 24 sata. Visoke vrijednosti MAPE (768%) i sMAPE (1.33) dodatno potvrđuju da model često promašuje smjer i veličinu odstupanja, osobito u intervalima kada su stvarne vrijednosti blizu nule. Usporedba skaliranih pogrešaka to jasno pokazuje: $MASE_1 = 2.35$ znači da je ovaj model više nego dvostruko lošiji od lag-1 baseline-a. Konačno, negativan $R^2 = -0.645$ ukazuje da model predviđa lošije nego jednostavno korištenje prosječne vrijednosti. To je još jedan znak da dnevna sezonalnost nije dovoljno stabilna da bi sama po sebi bila dobra metoda predviđanja. Sve zajedno, ove metrike pokazuju da je lag-96 baseline znatno slabiji od lag-1 baseline-a i da se oslanjanje isključivo na dnevni obrazac ne može smatrati pouzdanim pristupom predviđanja odstupanja.

3.5. Predviđanje jednostavnom linearnom regresijom

Predviđanje odstupanja jednostavnom linearne regresije predstavlja prvi korak prema izgradnji naprednijih modela. Za razliku od baseline pristupa, koji ne uči nikakve parametre, linearna regresija pokušava pronaći najbolju linearnu vezu između prošlih odstupanja (lagova) i buduće vrijednosti. Ovaj model je jednostavan, transparentan i računalno lagan, što ga čini idealnim polazištem za analizu odstupanja elektroenergetskog sustava.

3.5.1. Priprema podataka i modela

Prvi korak u izgradnji modela je priprema podataka. Polazimo od serije odstupanja u 15-minutnim intervalima, iz kojih generiramo ulazne značajke u obliku lagova. U ovoj fazi koristimo samo jedan lag, a to je lag-1, odnosno odstupanje iz prethodnog intervala. Po baseline modelima vidimo da je lag-1 bolji izbor od lag-96. Time model dobiva najosnovniju informaciju o kratkoročnoj dinamici sustava.

Podaci se pripremaju tako da se putem API-ja dohvate u obliku Pandas DataFrame-a [5] te se doda stupac za lag-1 koji predstavlja vrijednost iz prethodnog intervala. Ciljna varijabla je originalni stupac, dok je ulazna varijabla stupac za lag-1. Ovaj postupak omogućuje modelu da uči odnos između odstupanja u trenutku t_1 i odstupanja u trenutku t.

Koristit ćemo podatke za testiranje iz prvih 10 mjeseci 2025. godine.

Timestamp	Imbalance
2025-01-01 00:00:00	-24.869
2025-01-01 00:15:00	-13.097
2025-01-01 00:30:00	-4.941
2025-01-01 00:45:00	2.866
2025-01-01 01:00:00	-21.819

Tablica 3.3. Početak tablice podataka

Kao što se vidi u tablici 3.3., postoje vremenski intervali za svaki redak, no oni se ovdje zanemaruju te se gleda redoslijed vrijednosti odstupanja, a ne doba u koje se odvija odstupanje. Vremena navedena u tablici 3.3. označuju početak vremenskog intervala.

U ovoj osnovnoj verziji modela koristimo samo jedan ulazni lag, što znači da model ima oblik:

$$y_t = b_0 + b_1 \, y_{t-1}$$

Ovaj pristup omogućuje nam da procijenimo postoji li kratkoročna autokorelacija, koliko je jaka veza između uzastopnih intervala te može li jednostavan linearni odnos objasniti osnovnu dinamiku odstupanja. Kasnije, u naprednoj verziji modela, uvodimo veći broj lagova i modele po intervalima, ali ovdje je cilj postaviti najjednostavniji mogući linearni model.

3.5.2. Treniranje i evaluacija modela

Model se trenira korištenjem standardne metode najmanjih kvadrata. Linearna regresija pronalazi koeficijente b_0 i b_1 koji minimiziraju razliku između stvarnih i predviđenih vrijednosti.

Trening uključuje:

- prilagodba modela na povijesne podatke,
- dobivanje koeficijenata,
- generiranje predikcija na istom skupu podataka.

Ovaj pristup omogućuje nam da procijenimo koliko dobro model opisuje osnovnu strukturu serije.

$$b_0 = -0.8759270001786694 \qquad b_1 = 0.806561536693868$$

Pozitivan b_1 znači da veća prethodna vrijednost povećava predviđenu te je model proporcionalan s prethodnom vrijednosti, dok negativan b_0 lagano spušta ukupnu razinu modela i sugerira da očekuje manjak energije u sustavu.

Za evaluaciju koristimo standardne metrike koje omogućuju usporedbu s baseline modelima i procjenu koliko linearna regresija poboljšava predviđanje.

Metrika	**Lin. Reg.**	**Baseline lag-1**	**Baseline lag-96**
Mean	-4.52563585184168	-4.526443101850263	-4.542938696790191
Std	18.49110156298933	22.925235467066273	22.952246257000766
Median	-4.622068394461303	-4.646	-4.6705
Min	-87.47748419532641	-107.37	-107.37
Max	111.68314442246313	139.549	139.549
MAE	9.850959725895095	10.130113556005629	22.377740907838543
RMSE	13.551078325680795	14.258094820826281	29.398330822863265
MAPE	319.2358988833459	381.64466555493686	768.1154566590478
sMAPE	0.8500886436045596	0.8263838053473036	1.3327074378574715
$MASE_1$	1.2967261979661984	–	2.348478106937182
$MASE_{96}$	0.9662830778980763	1.0635674399412114	–
R^2	0.650593037718856	0.6131818526207347	-0.6448145055544481

Tablica 3.4. Metrike linearne regresije i dva baseline modela

Tablica 3.4. uspoređuje jednostavnu linearnu regresiju koja uzima prethodnu vrijednost s dva baseline naivna modela.

Rezultati jednostavne linearne regresije pokazuju da ovaj model dosljedno nadmašuje oba naivna baseline pristupa. U usporedbi s lag-1 modelom, linearna regresija postiže niži MAE (9.85 prema 10.13) i niži RMSE (13.55 prema 14.26), što znači da bolje hvata kratkoročne promjene i smanjuje utjecaj većih pogrešaka. To je očekivano jer linearna regresija ne kopira samo prethodnu vrijednost, nego uči optimalni koeficijent b1 koji ublažava ekstremne skokove i bolje prilagođava prosječnu dinamiku serije. U odnosu na lag-96 baseline, razlika je još izraženija: linearna regresija ima preko dvostruko

manji MAE i RMSE, što potvrđuje da dnevna sezonalnost sama po sebi nije dovoljno stabilna da bi bila dobar prediktor. Relativne metrike dodatno naglašavaju prednost linearnog modela: MAPE i sMAPE su znatno niži nego kod oba baseline-a, a MASE96 < 1 pokazuje da linearna regresija nadmašuje i dnevni sezonski model. Iako je MASE1 i dalje veći od 1 (1.30), što znači da je lag-1 baseline u strogo skaliranom smislu još uvijek nešto bolji, razlika je mala, a linearna regresija postiže najviši R^2 (0.651) među sva tri modela. To znači da objašnjava najveći dio varijance odstupanja i daje najstabilniju predikciju. Sveukupno, jednostavna linearna regresija predstavlja jasan korak naprijed u odnosu na oba naivna pristupa, posebno u pogledu smanjenja pogreške i boljeg opisivanja osnovne strukture vremenske serije.

3.5.3. Ograničenja jednostavne linearne regresije

Iako linearna regresija s jednim lagom može postići solidne rezultate u stabilnim dijelovima vremenske serije, ona ima nekoliko važnih ograničenja:

- Ne hvata nagle skokove u odstupanju, jer se oslanja samo na prethodni interval.
- Ne prepoznaje sezonalnost, budući da koristi samo jedan lag.
- Pretpostavlja linearnost, iako odstupanja često imaju nelinearne obrasce.
- Ne razlikuje različite dijelove dana, iako se dinamika sustava značajno mijenja tijekom 24 sata.

Zbog ovih ograničenja linearna regresija služi kao polazišna točka, ali ne i konačno rješenje. U sljedećem potpoglavlju uvodimo naprednu linearnu regresiju, koja koristi veći broj lagova, filtriranje lagova i precizno upravljanje dostupnošću podataka, čime se postiže znatno bolja točnost predviđanja.

3.6. Napredna linearna regresija i optimizacija lagova

Napredna linearna regresija predstavlja ključni korak u ovom radu jer omogućuje značajno poboljšanje točnosti predviđanja u odnosu na baseline modele i jednostavnu linearnu regresiju. Za razliku od jednostavnog pristupa koji koristi samo jedan lag, napredni model koristi optimizirani skup lagova, filtriranje kolinearnosti, modele po intervalima

i precizno upravljanje dostupnošću lagova prema tablici dostupnosti (Tablica 3.6.). Ovaj pristup omogućuje modelu da se prilagodi ograničenjima stvarnog sustava, gdje nisu svi podaci dostupni u trenutku pokretanja prognoze.

3.6.1. Selekcija lagova

Prvi korak u izgradnji naprednog modela je odabir utjecajnih lagova. Umjesto korištenja svih lagova od 1 do 192, što bi dovelo do prekomjernog učenja i kolinearnosti, koristi se kombinacija statističkih metoda:

- autokorelacijska funkcija (ACF)
- djelomična autokorelacijska funkcija (PACF)
- VIF analiza za uklanjanje kolinearnih značajki

ACF i PACF [8] omogućuju identifikaciju lagova koji imaju statistički značajan utjecaj na buduće odstupanje. U ovom radu pragovi su postavljeni na:

$$|\text{ACF}| > 0.12$$

$$|\text{PACF}| > 0.05$$

što daje početni skup kandidata. Nakon toga se primjenjuje VIF analiza [9] kako bi se uklonili lagovi koji su međusobno previše korelirani. Rezultat je filtrirani skup lagova koji čine ulazne značajke naprednog modela. Skup je vidljiv u Tablici 3.5.

Ovaj postupak osigurava da model koristi samo informativne i stabilne značajke, čime se smanjuje rizik od prekomjernog učenja i poboljšava generalizacija.

Nakon selekcije lagova, model se trenira korištenjem standardne višestruke linearne regresije [10]:

$$y_t = \beta_0 + \sum_{i \in L} \beta_i \, y_{t-i}$$

gdje je L skup odabranih lagova vidljiv u tablici 3.6.

Lag	Koeficijent
1	0.83863083
19	-0.00229849
21	0.03571952
22	0.02442457
24	-0.09547318
26	0.03280539
29	0.03278730
57	-0.00090705
61	0.00108166
65	0.00628874
69	0.00548950
73	0.01491395
89	-0.03201176
92	0.19271293
93	-0.16294222
95	0.09753882
97	-0.18771819
100	0.12674078
189	-0.09819950
192	0.11984242

Tablica 3.5. Lagovi i pripadajući koeficijenti naprednog modela

Ovaj model već pokazuje značajno poboljšanje u odnosu na baseline i osnovnu linearnu regresiju jer koristi više informacija iz prošlosti i bolje hvata strukturu vremenske serije.

3.6.2. Modeli po intervalima

Jedna od ključnih inovacija u ovom radu je korištenje različitih modela za različite intervale dana. Budući da se dinamika odstupanja značajno razlikuje između, primjerice, ranog jutra i večernjeg opterećenja, jedan globalni model ne može jednako dobro opisati sve intervale.

Zato se za svaki od 96 intervala koristi poseban model, ali svi modeli dijele iste koeficijente. Glavna razlika je samo u tome koji su lagovi dostupni u trenutku pokretanja prognoze.

Ovaj pristup omogućuje:

- bolju prilagodbu dnevnim obrascima,

- korištenje maksimalnog broja dostupnih informacija,
- izbjegavanje korištenja nedostupnih lagova.

Ključni dio sustava je tablica dostupnosti lagova (Tablica 3.6.). Ako se prognoza pokreće u 07:00, tada su dostupni samo oni lagovi čiji vremenski prozor završava strogo prije trenutka pokretanja prognoze. To znači da se skup dostupnih lagova smanjuje kako se predviđa sve raniji interval sljedećeg dana.

U ovom radu koristi se sljedeća tablica:

Skup modela	**Dostupni lagovi**
Model 1	[69, 73, 89, 92, 93, 95, 97, 100, 189, 192]
Modeli 2–5	[73, 89, 92, 93, 95, 97, 100, 189, 192]
Modeli 6–21	[89, 92, 93, 95, 97, 100, 189, 192]
Modeli 22–24	[92, 93, 95, 97, 100, 189, 192]
Model 25	[93, 95, 97, 100, 189, 192]
Modeli 26–27	[95, 97, 100, 189, 192]
Modeli 28–29	[97, 100, 189, 192]
Modeli 30–32	[100, 189, 192]
Modeli 33–96	[189, 192]

Tablica 3.6. Skupovi modela i pripadajući dostupni lagovi

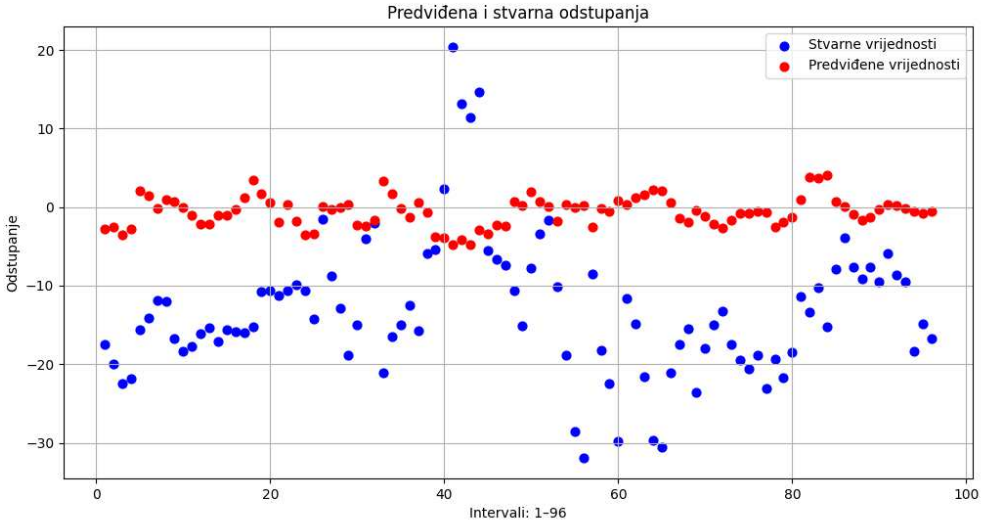
Tablica 3.6. je implementirana ručno u kodu, čime se osigurava da svaki model koristi točno one lagove koji su dostupni prema pravilima sustava.

3.6.3. Predviđanje odstupanja sljedećeg dana

Nakon treniranja modela i definiranja dostupnih lagova, generiraju se predikcije za svih 96 intervala sljedećeg dana. Za svaki interval:

1. odabire se odgovarajući skup lagova iz tablice 3.6.
2. primjenjuju se koeficijenti modela
3. izračunava se predikcija.

Slika 3.1. nam govori više toga o našem modelu. Konzervativnost modela je vrlo očita pri predviđanju, u usporedbi sa stvarnim podacima. Volumen je značajno manji od stvarnih podatka. Naglasak prilikom predviđanja je bio na predviđanju smjera odstupanja, tj.



Slika 3.1. Stvarno i predviđeno odstupanje

hoće li biti višak energije ili manjak energije u sustavu tokom nekog intervala te model ima točnost, što se tiče predviđanja smjera, od 57.291667%.

3.6.4. Usporedba s jednostavnom linearnom regresijom

Metrike	**LinReg baseline**	**LinReg napr. train**	**LinReg napr. test**	**Testiranje podaci**
Mean	-4.5256	-4.5077	-0.5943	-13.1099
Std	18.4911	19.4786	1.8785	8.8209
Median	-4.6221	-4.5763	-0.5392	-14.957
Min	-87.4775	-99.9191	-4.7465	-31.92
Max	111.6831	114.8708	4.0164	20.386
MAE	9.8510	8.7988	14.2295	–
RMSE	13.5511	12.1072	15.8363	–
MAPE	319.2359	357.9649	98.1945	–
sMAPE	0.8501	0.7857	1.7418	–
$MASE_1$	1.2967	0.8677	3.0984	–
$MASE_{96}$	0.9663	–	–	–
R^2	0.6506	0.7213	-2.2232	–
R^2_{adj}	–	0.7211	-2.2254	–

Tablica 3.7. Usporedba napredne i jednostavne linearne regresije

Vidimo razlike između modela te između podataka koji se primjenjuju na model u tablici 3.7. Na trening skupu, napredna linearna regresija pokazuje jasno poboljšanje u odnosu na jednostavnu verziju i baseline modele. MAE pada s 9.85 na 8.80, RMSE s 13.55 na 12.11, dok se sMAPE smanjuje s 0.850 na 0.786. Posebno važan rezultat je

$\text{MASE}_1 = 0.868$, prvi put manji od 1, što znači da model nadmašuje naivni lag-1 pristup. R^2 raste s 0.651 na 0.721, što potvrđuje da model objašnjava veći dio varijance i bolje hvata strukturu vremenske serije.

Na testnom skupu, koji je prvi dan studenog mjeseca 2025. godine, performanse se značajno pogoršavaju. MAE raste na 14.23, RMSE na 15.84, a sMAPE skače na 1.742, što ukazuje na česte promašaje u smjeru i veličini odstupanja. $\text{MASE}_1 = 3.10$ pokazuje da je model lošiji od jednostavnog lag-1 baseline-a, dok negativan $R^2 = -2.223$ znači da predviđanja na testu ispadaju lošija od korištenja prosječne vrijednosti. Ovi rezultati sugeriraju da model dobro uči povijesne obrasce, ali slabo generalizira na dane s drugačijom dinamikom odstupanja.

4. Rezultati te obrada metrika

Na trening skupu napredna linearna regresija pokazuje stabilno i uvjerljivo poboljšanje u odnosu na jednostavnu linearnu regresiju i oba baseline modela. Uvođenjem pažljivo odabranih lagova, prvo identificiranih kroz ACF/PACF analizu, a zatim filtriranih pomoću VIF-a, model dobiva informativnije ulazne značajke i izbjegava probleme kolinearnosti koji ograničavaju jednostavnije pristupe. Time se postiže smanjenje pogrešaka u apsolutnom i relativnom smislu, a model po prvi put nadmašuje i kratkoročni naivni lag-1 baseline, što je vidljivo kroz MASE_1 manji od 1. Povećanje R^2 dodatno potvrđuje da napredni model objašnjava veći dio varijance i bolje hvata dinamiku odstupanja. Sve to ukazuje da napredna linearna regresija na povijesnim podacima uspješno uči obrasce, sezonalnost i kratkoročne promjene te daje stabilnije i pouzdanije predikcije od jednostavne linearne regresije i baseline pristupa.

Na testnom skupu situacija je bitno drugačija. Kada se model suoči s novim danom koji odstupa od povijesnih obrazaca, performanse se pogoršavaju u svim metrikama. Pogreške rastu, relativne metrike pokazuju da model često promašuje i smjer i intenzitet odstupanja, a MASE_1 prelazi vrijednost 3, što znači da je model višestruko lošiji od jednostavnog lag-1 baseline-a. Negativan R^2 jasno pokazuje da predviđanja na testu nisu bolja od trivijalnog korištenja prosječne vrijednosti. Ovakav rezultat sugerira da napredna linearna regresija dobro funkcionira u stabilnim uvjetima, ali je osjetljiva na promjene obrazaca, nelinearne skokove i neuobičajene događaje koji se često pojavljuju u elektroenergetskim sustavima. Drugim riječima, model pokazuje snažnu sposobnost učenja povijesnih obrazaca, ali mu nedostaje robusnost potrebna za generalizaciju na dane s drugačijom strukturom odstupanja.

Širi pogled na ovu vrstu modela pokazuje da linearna regresija s višestrukim lagovima ima jasne prednosti, ali i ograničenja. Prednost je u tome što model može istovremeno

koristiti više vremenskih informacija, kratkoročne, srednjoročne i sezonske, te tako bolje opisati dinamiku sustava. Odabir lagova putem ACF/PACF analize omogućuje uključivanje samo onih vremenskih pomaka koji nose stvarnu informaciju, dok VIF filtriranje uklanja redundantne i kolinearne ulaze. Međutim, ovakav pristup ostaje linearan: model pretpostavlja da se utjecaj svakog laga može opisati linearnom kombinacijom, što dobro funkcionira u stabilnim uvjetima, ali teško hvata nelinearne skokove, promjene obrazaca ili situacije u kojima se odnos između ulaza i izlaza mijenja kroz vrijeme. Zbog toga se ovakvi modeli često odlično uklapaju u povijesne podatke, ali im nedostaje fleksibilnosti potrebne za robusnu generalizaciju u realnim operativnim uvjetima. U praksi, linearni modeli s lagovima predstavljaju snažnu i interpretabilnu osnovu, ali često služe kao početna točka prema složenijim metodama koje bolje hvataju nelinearnosti i promjenjive obrasce.

5. Zaključak

Ovaj rad je pokazao da linearna regresija s pažljivo odabranim lagovima može pružiti solidnu i interpretabilnu osnovu za modeliranje odstupanja u elektroenergetskom sustavu. Napredna verzija modela, koja koristi lagove odabrane ACF/PACF analizom i filtrirane VIF-om, jasno nadmašuje jednostavnu linearnu regresiju i baseline pristupe na trening skupu. Time potvrđuje da uključivanje informativnih vremenskih pomaka i uklanjanje kolinearnosti poboljšava sposobnost modela da uči sezonalnost, kratkoročne promjene i stabilne obrasce u povijesnim podacima. Međutim, rezultati na testnom skupu pokazuju da takav model ostaje osjetljiv na promjene obrazaca i neuobičajene događaje, što dovodi do značajnog pada performansi i gubitka generalizacijske sposobnosti. Linearna regresija se stoga pokazuje pouzdanom u stabilnim uvjetima, ali nedovoljno fleksibilnom za situacije u kojima se struktura odstupanja mijenja iz dana u dan.

Upravo zbog tih ograničenja logičan je korak prema naprednijim metodama koje bolje iskorištavaju nelinearnosti i vremensku strukturu podataka. Modeli poput Support Vector Regression-a (SVR) mogu uhvatiti složenije odnose između ulaza i izlaza zahvaljujući nelinearnim svojstvima, bez potrebe za ručnim odabirom lagova. Još veći potencijal nude sekvencijski modeli poput LSTM mreža i seq2seq arhitektura, koji su posebno dizajnirani za učenje dugoročnih ovisnosti i promjenjivih obrazaca u vremenskim serijama. Za razliku od linearne regresije, ovi modeli mogu automatski prepoznati bitne značajke, prilagoditi se nelinearnim skokovima i bolje generalizirati na dane koji odstupaju od povijesnih trendova. Zbog toga predstavljaju prirodan i obećavajući smjer za daljnje istraživanje, s potencijalom da značajno poboljšaju robusnost i točnost predviđanja u stvarnim uvjetima.

Literatura

[1] ENTSO-E, “Entso-e transparency platform”, https://transparency.entsoe.eu/, [Posjećena: travanj 2026.].

[2] ——, “Entso-e transparency - imbalance data”, https://transparencyplatform.zendesk.com/hc/en-us/articles/12824886606996-Imbalance-Prices-Total-Imbalance-Volumes-17-1-G-17-1-H, [Posjećena: travanj 2026.].

[3] HOPS d.d., “Pravila o uravnoteženju elektroenergetskog sustava”, HOPS pravilnik poslovanja, [Objavljeno: Zagreb, prosinac 2023.].

[4] ENTSO-E, “Entso-e data”, https://www.entsoe.eu/data/transparency-platform/, [Posjećena: travanj 2026.].

[5] Github - EnergieID, “Github api funkcioniranje”, https://github.com/EnergieID/entsoe-py, [Posjećena: travanj 2026.].

[6] Wikipedia, “Povijesno korištenje linearne regresije”, https://en.wikipedia.org/wiki/Linear_regression#History, [Posjećena: lipanj 2026.].

[7] GeeksforGeeks, “Općenito o jednostavnoj linearnoj regresiji u strojnom učenju”, https://www.geeksforgeeks.org/machine-learning/ml-linear-regression/, [Posjećena: travanj 2026.].

[8] ——, “Svrha i korištenje acf/pacf u strojnom učenju”, https://www.geeksforgeeks.org/r-machine-learning/autocorrelation-and-partial-autocorrelation/, [Posjećena: svibanj 2026.].

[9] ——, “Svrha i korištenje vif u strojnom učenju”, https://www.geeksforgeeks.org/python/detecting-multicollinearity-with-vif-python/, [Posjećena: svibanj 2026.].

[10] ——, “Višestruka linearna regresija u strojnom učenju”, https://www.geeksforgeeks.org/machine-learning/ml-multiple-linear-regression-using-python/, [Posjećena: svibanj 2026.].

Izjava o korištenju umjetne inteligencije

Koristio sam umjetnu inteligenciju prilikom izrade mog rada. Koristio sam Microsoft Copilot (dostupan putem internetske stranice 'https://copilot.microsoft.com'). Koristio sam u svrhu gramatičke točnosti i oblikovanja rečenice, objašnjavanja pojmova, objašnjavanja specifičnih funkcija u programiranju.

Osvrt na korištenje umjetne inteligencije: Značajno sam dorađivao generirani sadržaj kako bih mogao koristiti generirani materijal. Često je točan, ali se nerijetko događa da osjetno pogriješi. Ograničenja su prilikom navođenja ka cilju te rješava zadatak na svoj način bez obzira na upute koje mu zadam.

Izjava o korištenju umjetne inteligencije: Potvrđujem da sam tijekom izrade ovog završnog rada koristio umjetnu inteligenciju u skladu s Politikom primjerenog korištenja umjetne inteligencije na Fakultetu elektrotehnike i računarstva, te da umjetna inteligencija nije zamijenila moje kritičko razmišljanje niti moj doprinos.